
Realne funkcije više varijabli

1.1.2 Otvorena i zatvorena kugla. Sfera

Definicija 1.3 Neka je $\varepsilon > 0$ proizvoljan pozitivan realan broj i neka je $\mathbf{a} \in \mathbb{R}^n$.

Skup

$$K(\mathbf{a}, \varepsilon) = \{\mathbf{x} \in \mathbb{R}^n \mid d(\mathbf{a}, \mathbf{x}) < \varepsilon\}$$

nazivamo otvorenom kuglom u skupu $\mathbb{R}^n$ sa središtem u tački $\mathbf{a}$ i poluprečnikom ε . Skup

$$\overline{K}(\mathbf{a}, \varepsilon) = \{\mathbf{x} \in \mathbb{R}^n \mid d(\mathbf{a}, \mathbf{x}) \leq \varepsilon\}$$

nazivamo zatvorenom kuglom u $\mathbb{R}^n$ sa središtem u tački $\mathbf{a}$ i poluprečnikom ε . Skup

$$S(\mathbf{a}, \varepsilon) = \{\mathbf{x} \in \mathbb{R}^n \mid d(\mathbf{a}, \mathbf{x}) = \varepsilon\}$$

nazivamo sferom (loptom) u $\mathbb{R}^n$ sa središtem u tački $\mathbf{a}$ i poluprečnikom ε .

Definicija 1.4 Otvorenu kuglu $K(\mathbf{a}, \varepsilon)$ sa centrom u tački $\mathbf{a} \in \mathbb{R}^n$ i poluprečnikom ε nazivamo ε -okolinom tačke $\mathbf{a}$.

Definicija 1.5 Okolinom beskonačno daleke tačke nazivamo skup svih tačaka $\mathbf{x} \in \mathbb{R}^n$ za koje vrijedi

$$d(O_{\mathbb{R}^n}, \mathbf{x}) > M,$$

pri čemu je $M > 0$ proizvoljan realan broj.

Definicija 1.7 Za skup $S \subseteq \mathbb{R}^n$ kažemo da je otvoren skup ako za svaku tačku $\mathbf{x} \in S$ postoji $\varepsilon > 0$ tako da je ε -okolina tačke $\mathbf{x}$ sadržana u S , tj.

$$K(\mathbf{x}, \varepsilon) \subseteq S.$$

Definicija 1.10 Za skup S kažemo da je zatvoren ako je njegov komplement otvoren.

Definicija 1.8 Komplementom S^c skupa $S \subset \mathbb{R}^n$ nazivamo skup svih tačaka prostora $\mathbb{R}^n$ koje ne pripadaju skupu S .

Definicija 1.9 Za tačku $\mathbf{a}$ kažemo da je rubna tačka skupa ako svaka njena okolina sadrži i tačke skupa S i njegovog komplementa.

Skup svih rubnih tačaka nazivamo rubom skupa S i označavamo sa ∂S .

1.1.4 Ograničen skup. Kompaktan skup

Definicija 1.12 Za skup S kažemo da je ograničen ako postoji realan broj $M > 0$ tako da je skup S sadržan u kugli poluprečnika M .

Definicija 1.13 Za skup S kažemo da je kompaktan ako je zatvoren i ograničen.

1.1.5 Oblast u $\mathbb{R}^n$

Definicija 1.14 Skup tačaka

$$\{(x_1, x_2, \dots, x_n) \in \mathbb{R}^n \mid x_i = a_i + (b_i - a_i)t, \quad i = 1, \dots, n, t \in \mathbb{R}\}$$

nazivamo pravom u prostoru $\mathbb{R}^n$ koja prolazi tačkama $A(a_1, \dots, a_n)$ i $B(b_1, \dots, b_n)$.

Podskup prave sa krajnjim tačkama u A i B nazivamo duž $\overline{AB}$.

Definicija 1.15 Za skup $S \subseteq \mathbb{R}^n$ kažemo da je konveksan ako zajedno sa bilo koje dvije svoje tačke sadrži i linijski segment koji ih spaja.

Jednočlan skup i prazan skup smatramo konveksnim skupovima.

Definicija 1.16 Otvoren skup $S \subset \mathbb{R}^n$ je povezan ako se bilo koje dvije njegove tačke mogu spojiti sa konačno mnogo duži, tj. izlomljenom linijom

$$\overline{P_0 P_1} \cup \overline{P_1 P_2} \cup \dots \cup \overline{P_{k-1} P_k}$$

koja se sastoji samo od tačaka skupa.

Definicija 1.17 Otvoren i povezan skup $S \subseteq \mathbb{R}^n$ nazivamo (otvorena) oblast u $\mathbb{R}^n$.

Unija oblasti i njenog ruba se naziva zatvorena oblast.

Definicija 1.18 Oblast $S \subset \mathbb{R}^n$ je prosto ili jednostruko povezana ako je unutrašnjost svake zatvorene krive koja nema samopresijecanja također sadržana u S .

1.2 Pojam funkcije više varijabli

Definicija 1.20 Kažemo da je na skupu $X \subset \mathbb{R}^n$ definisana realna ili skalarna funkcija f n realnih varijabli ako je svakom elementu $\mathbf{x} = (x_1, x_2, \dots, x_n) \in X$ pridružen jedan i samo jedan realan broj y i pišemo

$$f(x_1, x_2, \dots, x_n) = y \quad \text{ili} \quad f(\mathbf{x}) = y, \quad y \in \mathbb{R}.$$

Realne brojeve $x_1, x_2, \dots, x_n$ nazivamo nezavisnim varijablama, argumentima ili promjenljivim funkcije f .

Definicija 1.21 *Grafik skalarne funkcije $f : \mathbb{R}^n \rightarrow \mathbb{R}$ je skup*

$$G = \{(x_1, x_2, \dots, x_n, x_{n+1}) \in \mathbb{R}^{n+1} | f(x_1, x_2, \dots, x_n) = x_{n+1} \in \mathbb{R}\}.$$

Svaka tačka $A(x_1^0, x_2^0, \dots, x_n^0, x_{n+1}^0) \in \mathbb{R}^{n+1}$ za koju tačka $M(x_1^0, x_2^0, \dots, x_n^0) \in \mathbb{R}^n$ pripada domenu funkcije f , a koordinata x_{n+1}^0 je jednaka vrijednosti funkcije u tački M , tj.

$$x_{n+1}^0 = f(x_1^0, x_2^0, \dots, x_n^0)$$

pripada grafiku funkcije.

Definicija 1.19 *Neka su $X \subset \mathbb{R}^n$ i $Y \subset \mathbb{R}^m$, $m \in \mathbb{N}$, $n \geq 2$. Ako jednoj tački $\mathbf{x} = (x_1, x_2, \dots, x_n) \in X$ po nekom zakonu ili pravilu f dodjeljujemo tačno jednu tačku $\mathbf{y} = (y_1, y_2, \dots, y_m) \in Y$, kažemo da je sa f definisana funkcija sa skupa X u skup Y i pišemo*

$$f : X \rightarrow Y.$$

Prethodno definisane funkcije više varijabli zavisno od kodomena mogu biti

1. skalarne ili realne funkcije više varijabli - funkcije čiji je kodomen skup $\mathbb{R}$,

$$f : \mathbb{R}^n \rightarrow \mathbb{R}.$$

2. vektorske funkcije više varijabli - funkcije čiji je kodomen skup $\mathbb{R}^m$,

$$\vec{f} : \mathbb{R}^n \rightarrow \mathbb{R}^m.$$

Definicija 1.22 *Nivo skupom funkcije $f : \mathbb{R}^n \rightarrow \mathbb{R}$ za nivo $c \in \mathbb{R}$ nazivamo skup*

$$L_c = \{(x_1, x_2, \dots, x_n) \in \mathbb{R}^n | f(x_1, x_2, \dots, x_n) = c\}.$$

Specijalno, za funkcije tri realne varijable skup L_c nazivamo nivo površ funkcije f .

Definicija 1.23 *Nivo površ funkcije $f : \mathbb{R}^3 \rightarrow \mathbb{R}$ za nivo $c \in \mathbb{R}$ je skup*

$$L_c = \{(x, y, z) \in \mathbb{R}^3 | f(x, y, z) = c\}.$$

Definicija 1.24 *Nivo linijom funkcije $f : \mathbb{R}^2 \rightarrow \mathbb{R}$ za nivo $c \in \mathbb{R}$ nazivamo skup*

$$L_c = \{(x, y) \in \mathbb{R}^2 | f(x, y) = c\}.$$

Limes realne funkcije više varijabli

Definicija 2.2 (Cauchyeva definicija limesa) Neka je $\mathbf{a} = (a_1, a_2, \dots, a_n) \in \mathbb{R}^n$ tačka gomilanja otvorenog skupa $D \subset \mathbb{R}^n$ koja može a i ne mora da mu pripada i neka je realna funkcija f definisana na skupu D . Kažemo da je realan broj A limes ili n -limes funkcije f u tački $\mathbf{a}$ i pišemo

$$\lim_{\mathbf{x} \rightarrow \mathbf{a}} f(\mathbf{x}) = A \quad \text{ili} \quad \lim_{(x_1, x_2, \dots, x_n) \rightarrow (a_1, a_2, \dots, a_n)} f(x_1, x_2, \dots, x_n) = A$$

ako za svako $\varepsilon > 0$ postoji $\delta = \delta(\varepsilon) > 0$ tako da vrijedi

$$0 < d(\mathbf{x}, \mathbf{a}) < \delta \Rightarrow |f(\mathbf{x}) - A| < \varepsilon.$$

Definicija 2.3 Neka je $\mathbf{a} = (a_1, a_2, \dots, a_n) \in \mathbb{R}^n$ tačka gomilanja otvorenog skupa $D \subset \mathbb{R}^n$ koja može a i ne mora da mu pripada i neka je realna funkcija f definisana na skupu D . Kažemo da je broj $A \in \mathbb{R}$ limes ili n -limes funkcije f u tački $\mathbf{a}$ i pišemo

$$\lim_{\mathbf{x} \rightarrow \mathbf{a}} f(\mathbf{x}) = A$$

ako za svako $\varepsilon > 0$ postoji $\delta = \delta(\varepsilon) > 0$ tako da vrijedi

$$(0 < |x_1 - a_1| < \delta, \dots, 0 < |x_n - a_n| < \delta) \Rightarrow |f(\mathbf{x}) - A| < \varepsilon.$$

Definicija 2.1 Tačka $\mathbf{a} \in \mathbb{R}^n$ je tačka gomilanja skupa $S \subseteq \mathbb{R}^n$ ako svaka otvorena okolina tačke $\mathbf{a}$ sadrži bar jednu tačku $\mathbf{x} \in S$ različitu od $\mathbf{a}$.

Teorem 2.1 Skup $S \subseteq \mathbb{R}^n$ je zatvoren ako i samo ako sadrži sve svoje tačke gomilanja.

Definicija 2.4 Neka je data funkcija $f : D \rightarrow \mathbb{R}$, $D \subseteq \mathbb{R}^2$. Kažemo da je broj $A \in \mathbb{R}$ limes ili dvostruki limes funkcije f kada $x \rightarrow a$, $y \rightarrow +\infty$ i pišemo

$$\lim_{\substack{x \rightarrow a \\ y \rightarrow +\infty}} f(x, y) = A$$

ako za svako $\varepsilon > 0$ postoje brojevi $\delta(\varepsilon) > 0$, $N(\varepsilon) > 0$ tako da vrijedi

$$(y > N \wedge |x - a| < \delta) \Rightarrow |f(x, y) - A| < \varepsilon$$

Kažemo da je broj $A \in \mathbb{R}$ limes ili dvostruki limes funkcije f kada $x \rightarrow +\infty$, $y \rightarrow +\infty$ i pišemo

$$\lim_{\substack{x \rightarrow +\infty \\ y \rightarrow +\infty}} f(x, y) = A$$

ako za svako $\varepsilon > 0$ postoji broj $N(\varepsilon) > 0$ tako da vrijedi

$$(x > N \wedge y > N) \Rightarrow |f(x, y) - A| < \varepsilon.$$

□ □ □ □ □

Definicija 2.5 Neka je $(\mathbf{x}_k)_{k \in \mathbb{N}}$ niz u $\mathbb{R}^n$. Kažemo da je tačka $\mathbf{a} \in \mathbb{R}^n$ tačka gomilanja niza $(\mathbf{x}_k)_{k \in \mathbb{N}}$ ako se za svako po volji malo $\varepsilon > 0$ u ε -okolini tačke $\mathbf{a}$ nalazi beskonačno mnogo članova datog niza.

Definicija 2.6 Neka je $(\mathbf{x}_k)_{k \in \mathbb{N}}$ niz u $\mathbb{R}^n$. Kažemo da je tačka $\mathbf{a} \in \mathbb{R}^n$ granična tačka ili limes niza $(\mathbf{x}_k)_{k \in \mathbb{N}}$ ili da niz $(\mathbf{x}_k)_{k \in \mathbb{N}}$ konvergira ka tački $\mathbf{a}$ i pišemo

$$\lim_{k \rightarrow \infty} \mathbf{x}_k = \mathbf{a}$$

ako za svako $\varepsilon > 0$ postoji $k_0 \in \mathbb{N}$ tako da je

$$d(\mathbf{x}_k, \mathbf{a}) < \varepsilon, \quad \forall k \geq k_0.$$

Definicija 2.7 (Heineova definicija limesa) Neka je $\mathbf{a} = (a_1, a_2, \dots, a_n) \in \mathbb{R}^n$ tačka gomilanja otvorenog skupa $D \subset \mathbb{R}^n$ koja može a i ne mora da mu pripada i neka je realna funkcija f definisana na skupu D . Kažemo da je realan broj A limes ili n -limes funkcije f kada $\mathbf{x} \rightarrow \mathbf{a}$ ako za svaki niz tačaka $(\mathbf{x}_k)_{k \in \mathbb{N}}$ za koji vrijedi

$$\lim_{k \rightarrow +\infty} \mathbf{x}_k = \mathbf{a}$$

vrijedi

$$\lim_{k \rightarrow +\infty} f(\mathbf{x}_k) = A$$

Teorem 2.4 (Teorem uklještenja) Neka su definisane funkcije $f, g, h : D \rightarrow \mathbb{R}$, $D \subseteq \mathbb{R}^n$, i neka je $\mathbf{a}$ tačka gomilana skupa D . Ako vrijedi

1. $f(\mathbf{x}) \leq h(\mathbf{x}) \leq g(\mathbf{x})$ za sve $\mathbf{x} \in D$,
2. postoje $\lim_{\mathbf{x} \rightarrow \mathbf{a}} f(\mathbf{x})$ i $\lim_{\mathbf{x} \rightarrow \mathbf{a}} g(\mathbf{x})$,
3. vrijedi $\lim_{\mathbf{x} \rightarrow \mathbf{a}} f(\mathbf{x}) = \lim_{\mathbf{x} \rightarrow \mathbf{a}} g(\mathbf{x}) = A \in \mathbb{R}$,

onda postoji i $\lim_{\mathbf{x} \rightarrow \mathbf{a}} h(\mathbf{x})$ i vrijedi

$$\lim_{\mathbf{x} \rightarrow \mathbf{a}} h(\mathbf{x}) = A.$$

Definicija 2.8 Limes funkcije $f(x, y)$ po promjenljivoj y u tački (x, b) je funkcija koja zavisi od x

$$F_1(x) = \lim_{y \rightarrow b} f(x, y).$$

Limes funkcije $f(x, y)$ po promjenljivoj x u tački (a, y) je funkcija koja zavisi od y

$$F_2(y) = \lim_{x \rightarrow a} f(x, y).$$

Definicija 2.9 Neka je definisana funkcija $f : \mathbb{R}^2 \rightarrow \mathbb{R}$.

Ako postoji granična funkcija $F_1(x)$ i ako za tu graničnu funkciju postoji limes u tački $x = a$ tada se

$$\lim_{x \rightarrow a} F_1(x) = \lim_{x \rightarrow a} \left(\lim_{y \rightarrow b} f(x, y) \right).$$

Naziva uzastopnim limesom (uzastopnom graničnom vrijednošću) funkcije $f(x, y)$ po promjenljivim y i x u tački (a, b) .

Ako postoji granična funkcija $F_2(y)$ i ako za tu graničnu funkciju postoji limes u tački $y = b$ tada se

$$\lim_{y \rightarrow b} F_2(y) = \lim_{y \rightarrow b} \left(\lim_{x \rightarrow a} f(x, y) \right).$$

Naziva uzastopnim limesom (uzastopnom graničnom vrijednošću) funkcije $f(x, y)$ po promjenljivim x i y u tački (a, b) .

Teorem 2.6 (Dovoljni uslovi za egzistenciju uzastopnog limesa) Neka je (a, b) tačka gomilanja skupa $D \subset \mathbb{R}^2$ i f realna funkcija definisana na D , osim možda u tački (a, b) . Ako postoji dvostruki limes

$$\lim_{(x, y) \rightarrow (a, b)} f(x, y) = A,$$

i ako za svaki $y \in \mathbb{R}$ za koji $(x, y) \in D$ postoji granična funkcija $F_2(y) = \lim_{x \rightarrow a} f(x, y)$, tada postoji uzastopni limes $\lim_{y \rightarrow b} \lim_{x \rightarrow a} f(x, y)$ i vrijedi

$$\lim_{y \rightarrow b} \lim_{x \rightarrow a} f(x, y) = A$$

Neprekidnost realne funkcije više varijabli

3.1 Cauchyeva definicija neprekidnosti

Neka je $D \subset \mathbb{R}^n$ otvoren skup, tj. svaka tačka skupa D pripada tom skupu zajedno sa nekom svojom okolinom.

Definicija 3.2 Funkcija $f : D \subseteq \mathbb{R}^2 \rightarrow \mathbb{R}$ je neprekidna u tački $(a, b) \in D$ ako za svako $\varepsilon > 0$ postoji $\delta = \delta(\varepsilon) > 0$ tako da za sve $(x, y) \in D$ vrijedi

$$\sqrt{(x-a)^2 + (y-b)^2} < \delta \Rightarrow |f(x, y) - f(a, b)| < \varepsilon,$$

tj.

$$\lim_{(x,y) \rightarrow (a,b)} f(x, y) = f(a, b)$$

Definicija 3.4 (Heineova definicija neprekidnosti) Funkcija $f : D \subseteq \mathbb{R}^2 \rightarrow \mathbb{R}$ je neprekidna u tački $(a, b) \in D$ ako i samo ako za svaki niz $(x_k, y_k)_{k \in \mathbb{N}}$ takav da je

$$\lim_{k \rightarrow \infty} (x_k, y_k) = (a, b)$$

vrijedi

$$\lim_{k \rightarrow \infty} f(x_k, y_k) = f(a, b),$$

Definicija 3.6 (Heineova definicija uniformne neprekidnosti) Kažemo da je funkcija $f : \mathbb{R}^n \rightarrow \mathbb{R}$ uniformno neprekidna na nekom skupu $E \subset D$ ako vrijedi: za svaka dva niza $(\mathbf{P}_k)_{k \in \mathbb{N}}, (\mathbf{Q}_k)_{k \in \mathbb{N}}$ takva da vrijedi

$$\lim_{k \rightarrow \infty} d(\mathbf{P}_k, \mathbf{Q}_k) = 0 \Rightarrow |f(\mathbf{P}_k) - f(\mathbf{Q}_k)| \rightarrow 0 \text{ kada } k \rightarrow \infty.$$

Teorem 3.5 (Cantorov teorem) Ako je funkcija f definisana i neprekidna u zatvorenoj i ograničenoj oblasti $D \subseteq \mathbb{R}^n$, onda je ona uniformno neprekidna u toj oblasti.

3.4 Osobine neprekidnih funkcija definisanih u oblasti

Teorem 3.2 (Weierstrassov teorem I) *Ako je funkcija f definisana i neprekidna u zatvorenoj i ograničenoj (kompaktnoj) oblasti $D \subseteq \mathbb{R}^n$, onda je f ograničena u toj oblasti*

Teorem 3.3 (Weierstrassov teorem II) *Ako je funkcija f definisana i neprekidna u zatvorenoj i ograničenoj (kompaktnoj) oblasti $D \subseteq \mathbb{R}^n$, onda postoje bar jedna tačka u kojoj funkcija ima najveću vrijednost i bar jedna tačka u kojoj funkcija ima najmanju vrijednost.*

Teorem 3.4 (Teorem o međuvrijednosti) *Ako je funkcija f definisana i neprekidna u otvorenoj ili zatvorenoj oblasti $D \subseteq \mathbb{R}^n$ i ako za tačke $\mathbf{A}, \mathbf{B} \in D$ vrijedi*

$$f(\mathbf{A}) < f(\mathbf{B}),$$

tada za bilo koji broj $C \in \mathbb{R}$ takav da je

$$f(\mathbf{A}) < C < f(\mathbf{B})$$

postoji bar jedna tačka $\mathbf{E} \in D$ takva da je $f(\mathbf{E}) = C$.

3.5 Uniformna neprekidnost

Definicija 3.5 *Kažemo da je funkcija $f : D \rightarrow \mathbb{R}$, $D \subset \mathbb{R}^n$, uniformno neprekidna na nekom skupu $E \subset D$ ako za proizvoljno $\varepsilon > 0$ postoji $\delta > 0$ tako da svake dvije tačke $\mathbf{x} = (x_1, x_2, \dots, x_n)$, $\mathbf{y} = (y_1, y_2, \dots, y_n)$ vrijedi*

$$d(\mathbf{x}, \mathbf{y}) < \delta \Rightarrow |f(\mathbf{x}) - f(\mathbf{y})| < \varepsilon.$$

Diferencijalni račun realne funkcije više varijabli

Teorem 4.3 *Neka je funkcija f definisana u oblasti $D \subseteq \mathbb{R}^n$ i neka je svaka od varijabli x_k , $k = 1, \dots, n$, funkcija m nezavisnih varijabli $t_1, \dots, t_m$, tj.*

$$x_k = x_k(t_1, \dots, t_m), \quad k = 1, \dots, n.$$

Ukoliko postoje neprekidni parcijalni izvodi $\frac{\partial f}{\partial x_k}$, $k = 1, \dots, n$, i za svako x_k postoje neprekidni parcijalni izvodi $\frac{\partial x_k}{\partial t_i}$, $i = 1, \dots, m$, onda postoje i parcijalni izvodi $\frac{\partial f}{\partial t_i}$, $i = 1, \dots, m$, i dati su sa

$$\frac{\partial f}{\partial t_i} = \frac{\partial f}{\partial x_1} \frac{\partial x_1}{\partial t_i} + \dots + \frac{\partial f}{\partial x_n} \frac{\partial x_n}{\partial t_i}, \quad i = 1, \dots, m.$$

4.1.2 Parcijalni izvod realne funkcije više varijabli

Definicija 4.3 Kažemo da funkcija $f : D \rightarrow \mathbb{R}$, gdje je $D \subseteq \mathbb{R}^n$ otvoren skup, ima prvi parcijalni izvod po varijabli x_k u tački $(x_1^0, \dots, x_n^0) \in D$ ako postoji limes

$$\lim_{\Delta x_k \rightarrow 0} \frac{f(x_1^0, x_2^0, \dots, x_k^0 + \Delta x_k, \dots, x_n^0) - f(x_1^0, \dots, x_n^0)}{\Delta x_k}.$$

i pišemo

$$f'_{x_k}(x_1^0, \dots, x_n^0) = \lim_{\Delta x_k \rightarrow 0} \frac{f(x_1^0, \dots, x_k^0 + \Delta x_k, \dots, x_n^0) - f(x_1^0, \dots, x_n^0)}{\Delta x_k}.$$

Teorem 4.4 Neka je funkcija $F(x_1, \dots, x_n, z) : D \rightarrow \mathbb{R}$, gdje je $D \subseteq \mathbb{R}^{n+1}$ definisana u okolini tačke $\mathbf{x}_0 = (x_1^0, \dots, x_n^0, z_0) \in D$ pri čemu vrijedi

1. F ima neprekidne parcijalne izvode do p -tog reda zaključno u okolini tačke $\mathbf{x}_0$
2. $F(\mathbf{x}_0) = 0$,
3. $\frac{\partial F}{\partial z}(\mathbf{x}_0) \neq 0$.

Tada postoji jedinstvena funkcija $z = f(x_1, \dots, x_n)$ koja ima neprekidne parcijalne izvode u okolini tačke $(x_1^0, \dots, x_n^0)$ tako da vrijedi

1. $z_0 = f(x_1^0, \dots, x_n^0)$,
2. $F(x_1, \dots, x_n, f(x_1, \dots, x_n)) = 0$ za tačke $(x_1, \dots, x_n)$ u okolini tačke $(x_1^0, \dots, x_n^0)$,
3. $\frac{\partial z}{\partial x_i}(x_1, \dots, x_n) = -\frac{\frac{\partial F}{\partial x_i}(x_1, \dots, x_n, f(x_1, \dots, x_n))}{\frac{\partial F}{\partial z}(x_1, \dots, x_n, f(x_1, \dots, x_n))}$.

Definicija 4.6 Totalni (Potpuni) prirast realne funkcije $f : D \rightarrow \mathbb{R}$, $D \subseteq \mathbb{R}^n$, u tački $(x_1^0, \dots, x_n^0) \in D$ definišemo kao

$$\Delta f(x_1^0, \dots, x_n^0) = f(x_1^0 + \Delta x_1, \dots, x_n^0 + \Delta x_n) - f(x_1^0, \dots, x_n^0),$$

pri čemu su $\Delta x_1, \dots, \Delta x_n \in \mathbb{R}$ takvi da vrijedi

$$(x_1^0, \dots, x_n^0), (x_1^0 + \Delta x_1, \dots, x_n^0 + \Delta x_n) \in D.$$

Sada uvodimo pojam diferencijabilnosti funkcije.

Definicija 4.7 Neka je $f : D \rightarrow \mathbb{R}$, gdje je $D \subset \mathbb{R}^n$ otvoren skup. Kažemo da je funkcija f diferencijabilna u tački $\mathbf{x}_0 = (x_1^0, x_2^0, \dots, x_n^0) \in D$ ako postoji linearna funkcija prirasta nezavisnih varijabli (tzv. izvodna funkcija)

$$L = L_1 \Delta x_1 + \dots + L_n \Delta x_n, \quad L_i \in \mathbb{R}$$

tako da se njen totalni prirast $\Delta f(x_1^0, \dots, x_n^0)$ može zapisati u obliku

$$\Delta f(x_1^0, \dots, x_n^0) = L_1 \Delta x_1 + \dots + L_n \Delta x_n + \omega(\Delta x_1, \dots, \Delta x_n) \sqrt{(\Delta x_1)^2 + \dots + (\Delta x_n)^2},$$

gdje

$$\lim_{\substack{\Delta x_1 \rightarrow 0 \\ \dots \\ \Delta x_n \rightarrow 0}} \omega(\Delta x_1, \dots, \Delta x_n) = 0.$$

Ekvivalentna je sljedeća definicija

Definicija 4.8 Neka je $f : D \rightarrow \mathbb{R}$, gdje je $D \subset \mathbb{R}^n$ otvoren skup. Kažemo da je funkcija f diferencijabilna u tački $\mathbf{x}_0 = (x_1^0, x_2^0, \dots, x_n^0) \in D$ ako postoji linearna funkcija prirasta nezavisnih varijabli (tzv. izvodna funkcija)

$$L = L_1 \Delta x_1 + \dots + L_n \Delta x_n, \quad L_i \in \mathbb{R}$$

takva da vrijedi

$$\lim_{\substack{\Delta x_1 \rightarrow 0 \\ \dots \\ \Delta x_n \rightarrow 0}} \frac{f(x_1^0 + \Delta x_1, x_2^0 + \Delta x_2, \dots, x_n^0 + \Delta x_n) - f(x_1^0, x_2^0, \dots, x_n^0) - L_1 \Delta x_1 - \dots - L_n \Delta x_n}{\sqrt{(\Delta x_1)^2 + \dots + (\Delta x_n)^2}} = 0.$$

Sljedeći teorem nam daje potrebne i dovoljne uslove za diferencijabilnost realne funkcije više varijabli.

Teorem 4.6 Neka je $f : D \rightarrow \mathbb{R}$, gdje je $D \subseteq \mathbb{R}^n$ otvoren skup, i $\mathbf{x}_0 = (x_1^0, x_2^0, \dots, x_n^0) \in D$.

1. Ako je funkcija f diferencijabilna u tački $\mathbf{x}_0$, onda je ona u toj tački neprekidna.
2. Ako je funkcija f diferencijabilna u tački $\mathbf{x}_0$, tj ako postoje brojevi $L_1, \dots, L_n$ iz definicije diferencijabilnosti, onda f ima parcijalne izvode u $\mathbf{x}_0$ i vrijedi

$$L_i = \frac{\partial f}{\partial x_i}(\mathbf{x}_0), \quad i = 1, 2, \dots, n.$$

3. Ako prvi parcijalni izvodi funkcije f postoje u okolini tačke $\mathbf{x}_0$ i ako su oni neprekidne funkcije u tački $\mathbf{x}_0$, onda je funkcija f diferencijabilna funkcija u tački $\mathbf{x}_0$.

Definicija 4.9 Neka je funkcija $f : D \rightarrow \mathbb{R}$, $D \subseteq \mathbb{R}^n$, diferencijabilna. Izraz

$$df(\mathbf{x}_0) = \frac{\partial f}{\partial x_1}(\mathbf{x}_0)\Delta x_1 + \dots + \frac{\partial f}{\partial x_n}(\mathbf{x}_0)\Delta x_n$$

nazivamo (totalnim) diferencijalom funkcije $f(x_1, \dots, x_n)$ u tački $\mathbf{x}_0 = (x_1^0, \dots, x_n^0)$.

Kako za nezavisne varijable x_i vrijedi $\Delta x_i = dx_i$, diferencijal funkcije zapisujemo izrazom

$$df(\mathbf{x}_0) = \frac{\partial f}{\partial x_1}(\mathbf{x}_0)dx_1 + \dots + \frac{\partial f}{\partial x_n}(\mathbf{x}_0)dx_n.$$

Definicija 4.13 Ravan α nazivamo tangentnom (dodirnom) ravni površi $z = f(x, y)$ u tački P ako se odnos udaljenosti $d(P_1, P)$ i $d(P_1, P'_1)$ može napisati u obliku

$$\frac{d(P_1, P'_1)}{d(P_1, P)} = \omega(P_1)$$

pri čemu je

$$\lim_{P_1 \rightarrow P} \omega(P_1) = 0$$

Teorem 4.9 Potreban i dovoljan uslov za egzistenciju tangentne ravni koja nije paralelna sa z -osom u tački $P(x_0, y_0, z_0)$ na površi $z = f(x, y)$ je diferencijabilnost funkcije $f(x, y)$ u tački (x_0, y_0)

4.3 Izvod realne funkcije više varijabli u pravcu jediničnog vektora

Definicija 4.14 Neka je $\vec{v} = (v_1, v_2, \dots, v_n)$ proizvoljan jedinični vektor. Kažemo da funkcija $f : D \rightarrow \mathbb{R}$, $D \subseteq \mathbb{R}^n$ otvoren skup, ima izvod u pravcu vektora $\vec{v}$ u tački $\mathbf{x}_0 = (x_1^0, x_2^0, \dots, x_n^0)$ ako postoji limes

$$\frac{\partial f}{\partial \vec{v}}(x_1^0, x_2^0, \dots, x_n^0) = \lim_{h \rightarrow 0} \frac{f((x_1^0, x_2^0, \dots, x_n^0) + h(v_1, v_2, \dots, v_n)) - f(x_1^0, x_2^0, \dots, x_n^0)}{h}.$$

Za izvod funkcije f u pravcu vektora $\vec{v}$ koristimo još i oznaku $f'_{\vec{v}}(x_1^0, x_2^0, \dots, x_n^0)$.

4.3.1 Izvod realne funkcije dvije varijable u pravcu proizvoljnog vektora

Definicija 4.15 Neka je $\vec{v} = (a, b)$ proizvoljan jedinični vektor. Kažemo da funkcija $f : D \rightarrow \mathbb{R}$, gdje je $D \subseteq \mathbb{R}^2$ otvoren skup, ima izvod u pravcu vektora $\vec{v}$ u tački (x_0, y_0) ako postoji limes

$$\frac{\partial f}{\partial \vec{v}}(x_0, y_0) = f'_{\vec{v}}(x_0, y_0) = \lim_{h \rightarrow 0} \frac{f(x_0 + ha, y_0 + hb) - f(x_0, y_0)}{h}.$$

4.3.2 Gradijent realne funkcije više varijabli

Definicija 4.16 Neka je funkcija $f(x_1, x_2, \dots, x_n)$ definisana u nekoj okolini tačke $\mathbf{x}_0 = (x_1^0, x_2^0, \dots, x_n^0)$ i neka postoje $\frac{\partial f}{\partial x_k}(\mathbf{x}_0)$ za sve $k = 1, 2, \dots, n$. Vektor

$$\nabla f(\mathbf{x}_0) = \left(\frac{\partial f}{\partial x_1}(\mathbf{x}_0), \frac{\partial f}{\partial x_2}(\mathbf{x}_0), \dots, \frac{\partial f}{\partial x_n}(\mathbf{x}_0) \right)$$

Definicija 4.17 Neka je funkcija $f(x, y)$ definisana u nekoj okolini tačke (x_0, y_0) i neka postoje $\frac{\partial f}{\partial x}(x_0, y_0)$ i $\frac{\partial f}{\partial y}(x_0, y_0)$. Gradijentom funkcije f u tački (x_0, y_0) nazivamo vektor čije su projekcije na ose dekartovog pravouglog koordinatnog sistema jednake parcijalnim izvodima funkcije u tački (x_0, y_0)

$$\nabla f(x_0, y_0) = \left(\frac{\partial f}{\partial x}(x_0, y_0), \frac{\partial f}{\partial y}(x_0, y_0) \right).$$

4.4.1 Parcijalni izvodi višeg reda realne funkcije dvije varijable

Definicija 4.18 Parcijalnim izvodom k -tog reda po promjenljivim $x_1, \dots, x_k \in \{x, y\}$ funkcije $f : D \rightarrow \mathbb{R}$, $D \subseteq \mathbb{R}^2$, naziva se parcijalni izvod po promjenljivoj $x_k \in \{x, y\}$ funkcije $\frac{\partial^k f}{\partial x_k \partial x_{k-1} \dots \partial x_2 \partial x_1}$ i označava sa

$$\frac{\partial^k f}{\partial x_k \partial x_{k-1} \dots \partial x_2 \partial x_1} = \frac{\partial f}{\partial x_k} \left(\frac{\partial^{k-1} f}{\partial x_{k-1} \dots \partial x_2 \partial x_1} \right)$$

4.4.3 Taylorova formula za realne funkcije dvije varijable

Neka realna funkcija f ima neprekidne parcijalne izvode do reda n zaključno u oblasti $D \subseteq \mathbb{R}^2$. Tada u okolini tačke $A(x_0, y_0) \in D$ vrijedi Taylorova formula

$$\begin{aligned} f(x, y) = & f(x_0, y_0) + \frac{1}{1!} \left(dx \frac{\partial}{\partial x} + dy \frac{\partial}{\partial y} \right) f(x_0, y_0) + \frac{1}{2!} \left(dx \frac{\partial}{\partial x} + dy \frac{\partial}{\partial y} \right)^2 f(x_0, y_0) \\ & + \dots + \frac{1}{(n-1)!} \left(dx \frac{\partial}{\partial x} + dy \frac{\partial}{\partial y} \right)^{n-1} f(x_0, y_0) + \frac{1}{n!} \left(dx \frac{\partial}{\partial x} + dy \frac{\partial}{\partial y} \right)^n f(x_0 + \lambda \Delta x, y_0 + \lambda \Delta y) \end{aligned}$$

gdje je $\Delta x = x - x_0$, $\Delta y = y - y_0$ i $0 < \lambda < 1$ zavisi od tačke (x, y) .

Taylorovu formulu za funkcije dvije varijable možemo kraće zapisati u obliku

$$f(x, y) = T_{n-1}(x_0, y_0) + R_n(x_0, y_0)$$

gdje je u Lagrangeovom obliku ostatak dat sa

$$R_n(x_0, y_0) = \frac{1}{n!} \left(dx \frac{\partial}{\partial x} + dy \frac{\partial}{\partial y} \right)^n f(x_0 + \lambda \Delta x, y_0 + \lambda \Delta y).$$

Ako je $(x_0, y_0) = (0, 0)$ odgovarajuću formulu nazivamo MacLaurinova formula. Svrha Taylorovog polinoma je da se funkcija njime dovoljno dobro aproksimira u okolini neke tačke.

4.5 Lokalni ekstrem realne funkcije više varijabli

Definicija 4.19 Neka je na oblasti $D \subseteq \mathbb{R}^n$ definisana funkcija f i neka je $\mathbf{x}_0 = (x_1^0, \dots, x_n^0)$ fiksna tačka u oblasti D . Kažemo da je u tački $\mathbf{x}_0$ lokalni minimum funkcije f ako postoji okolina $\mathcal{U}(\mathbf{x}_0) \subset D$ tačke $\mathbf{x}_0$ za koju vrijedi

$$f(\mathbf{x}_0) \leq f(\mathbf{x}), \quad \mathbf{x} \in \overset{\circ}{\mathcal{U}}(\mathbf{x}_0). \quad (4.12)$$

Kažemo da je u tački $\mathbf{x}_0$ lokalni maksimum funkcije f ako postoji okolina $\mathcal{U}(\mathbf{x}_0) \subset D$ tačke $\mathbf{x}_0$ za koju vrijedi

$$f(\mathbf{x}_0) \geq f(\mathbf{x}), \quad \mathbf{x} \in \overset{\circ}{\mathcal{U}}(\mathbf{x}_0). \quad (4.13)$$

Ako u 4.12, odnosno 4.13, vrijede stroge nejednakosti, kažemo da je u tački $\mathbf{x}_0$ strogi lokalni minimum, odnosno maksimum, funkcije f .

Lokalni minimum i maksimum nazivamo lokalnim ekstremima funkcije f . Primijetimo da iz nejednakosti (4.12) slijedi da u slučaju kada je $\mathbf{x}_0 \in D$ lokalni minimum funkcije f , onda postoji okolina $\mathcal{U}(\mathbf{x}_0) \subset D$ tačke $\mathbf{x}_0$ tako da za sve $\mathbf{x} \in \overset{\circ}{\mathcal{U}}(\mathbf{x}_0)$ vrijedi

$$\Delta f(\mathbf{x}_0) = f(\mathbf{x}) - f(\mathbf{x}_0) \geq 0, \quad \mathbf{x} \in U_0.$$

Analogno, iz (4.13) slijedi da u slučaju kada je $\mathbf{x}_0 \in D$ lokalni maksimum funkcije f , onda postoji okolina $\mathcal{U}(\mathbf{x}_0) \subset D$ tačke $\mathbf{x}_0$ tako da za sve $\mathbf{x} \in \overset{\circ}{\mathcal{U}}(\mathbf{x}_0)$ vrijedi

$$\Delta f(\mathbf{x}_0) = f(\mathbf{x}) - f(\mathbf{x}_0) \leq 0 \quad \mathbf{x} \in U_0.$$

Otuda se ispitivanje egzistencije lokalnog ekstrema funkcije f u nekoj tački $\mathbf{x}_0$ svodi na ispitivanje znaka totalnog $\Delta f(\mathbf{x}_0)$ prirasta funkcije f u toj tački. Ako je prirast funkcije $\Delta f(\mathbf{x}_0)$ istog znaka za sve $\mathbf{x} \in \overset{\circ}{\mathcal{U}}(\mathbf{x}_0)$, onda u tački $\mathbf{x}_0$ funkcija ima ekstrem.

Definicija 4.20 Neka je data funkcija funkcija $f : D \rightarrow \mathbb{R}$, $D \subseteq \mathbb{R}^n$. Tačku $\mathbf{x}_0 \in D$ u kojoj postoje parcijalni izvodi prvog reda funkcije f po varijablama

$x_1, \dots, x_n$ i u kojoj vrijedi

$$\frac{\partial f}{\partial x_1}(\mathbf{x}_0) = \dots = \frac{\partial f}{\partial x_n}(\mathbf{x}_0) = 0$$

nazivamo stacionarnom tačkom funkcije f .

Neka je funkcija $f : U \rightarrow \mathbb{R}$, $D \subseteq \mathbb{R}^n$, dva puta neprekidno diferencijabilna i neka je $\mathbf{x}_0 = (x_1^0, \dots, x_n^0) \in U$ stacionarna tačka funkcije f .

Definicija 4.21 *Hessianovom matricom nazivamo matricu datu sa*

$$H = \begin{bmatrix} \frac{\partial^2 f}{\partial x_1^2} & \frac{\partial^2 f}{\partial x_1 \partial x_2} & \dots & \frac{\partial^2 f}{\partial x_1 \partial x_n} \\ \frac{\partial^2 f}{\partial x_2 \partial x_1} & \frac{\partial^2 f}{\partial x_2^2} & \dots & \frac{\partial^2 f}{\partial x_2 \partial x_n} \\ \vdots & \vdots & \ddots & \vdots \\ \frac{\partial^2 f}{\partial x_n \partial x_1} & \frac{\partial^2 f}{\partial x_n \partial x_2} & \dots & \frac{\partial^2 f}{\partial x_n^2} \end{bmatrix}$$

Teorem 4.13 (Sylvesterov kriterij za egzistenciju lokalnog ekstrema) *Neka je funkcija $f : U \subseteq \mathbb{R}^n \rightarrow \mathbb{R}$ dva puta diferencijabilna. Neka je $\mathbf{x}_0 = (x_1^0, \dots, x_n^0) \in U$ stacionarna tačka funkcije f i $D_i(\mathbf{x}_0)$, $i = 1, \dots, n$, glavni minori Hessianove matrice funkcije f u tački $\mathbf{x}_0$. Tada vrijedi*

1. *Ako je $D_i(\mathbf{x}_0) > 0$ za $i = 1, \dots, n$, onda je u tački $\mathbf{x}_0$ lokalni minimum.*
2. *Ako je $D_1(\mathbf{x}_0) < 0$, $D_2(\mathbf{x}_0) > 0$, $D_3(\mathbf{x}_0) < 0$, ..., $(-1)^n D_n(\mathbf{x}_0) > 0$, onda je u tački $\mathbf{x}_0$ lokalni maksimum.*
3. *Ako su $D_i(\mathbf{x}_0) \neq 0$ za $i = 1, \dots, n$, ali ne vrijede slučajevi 1. i 2., onda je u tački $\mathbf{x}_0$ sedlo.*
4. *Ako je neka od determinanti $D_i(\mathbf{x}_0)$ jednaka nuli, onda ne znamo prirodu stacionarne tačke $\mathbf{x}_0$.*

Specijalno, za funkcije dvije varijable Sylvesterov kriterij se svodi na sljedeći teorem.

Teorem 4.14 (*Dovoljni uslovi za egzistenciju lokalnog ekstrema funkcije dvije varijable) *Neka je funkcija $f : U \subseteq \mathbb{R}^2 \rightarrow \mathbb{R}$ dva puta diferencijabilna na skupu U i $(x_0, y_0) \in U$ stacionarna tačka funkcije f . Definišimo*

$$D(x_0, y_0) = f''_{xx}(x_0, y_0)f''_{yy}(x_0, y_0) - \left(f''_{xy}(x_0, y_0)\right)^2.$$

Tada vrijedi

1. *Ako je $D(x_0, y_0) > 0$ i $f''_{xx}(x_0, y_0) > 0$, u tački (x_0, y_0) je lokalni minimum funkcije;*
2. *Ako je $D(x_0, y_0) > 0$ i $f''_{xx}(x_0, y_0) < 0$, u tački (x_0, y_0) je lokalni maksimum funkcije;*
3. *Ako je $D(x_0, y_0) < 0$, u tački (x_0, y_0) funkcija nema ekstrem (sedlasta tačka);*

Definicija 4.22 Neka je na oblasti $D \subseteq \mathbb{R}^n$ definisana funkcija f i neka je $\mathbf{x}_0 = (x_1^0, \dots, x_n^0)$ fiksna tačka u oblasti D . Kažemo da je u tački $\mathbf{x}_0$ uslovni minimum (maksimum) funkcije f dostignut pod uslovima

$$g_i(x_1, \dots, x_n) = 0, \quad i = 1, \dots, m, \quad m < n, \quad (4.15)$$

ako postoji okolina $\mathcal{U}(\mathbf{x}_0)$ tačke $\mathbf{x}_0$ tako da za sve $\mathbf{x} \in \mathcal{U}(\mathbf{x}_0)$ koji zadovoljavaju uslove 4.15 vrijedi

$$f(\mathbf{x}_0) \leq f(\mathbf{x}), \quad f(\mathbf{x}_0) \geq f(\mathbf{x}), \quad \mathbf{x} \in \mathcal{U}(\mathbf{x}_0) \cap D. \quad (4.16)$$

Ako u 4.16 vrijede stroge nejednakosti, kažemo da je u tački $\mathbf{x}_0$ strogi uslovni minimum, odnosno maksimum, funkcije f .

Teorem 4.15 Neka su funkcije f i g definisane na skupu $D \subseteq \mathbb{R}^2$ i neka na D imaju neprekidne parcijalne izvode. Ako je tačka (x_0, y_0) ekstrem funkcije f pod uslovom $g(x, y) = k$, pri čemu je $\nabla g(x_0, y_0) \neq 0$, onda postoji $\lambda \in \mathbb{R}$ tako da vrijedi

$$\nabla f(x_0, y_0) = \lambda \nabla g(x_0, y_0). \quad (4.20)$$

Broj $\lambda \in \mathbb{R}$ iz relacije (4.20) nazivamo Lagrangeovim multiplikatorom.

Vektorske funkcije

Definicija 1.1 Neka su $X \subset \mathbb{R}^n$ i $Y \subset \mathbb{R}^m$, $m, n \in \mathbb{N}$, $m \geq 2$. Ako jednoj tački $\mathbf{x} = (x_1, x_2, \dots, x_n) \in X$ po nekom zakonu ili pravilu f dodjeljujemo tačno jednu vrijednost $\mathbf{y} = (y_1, y_2, \dots, y_m) \in Y$, kažemo da je sa f definisana funkcija sa skupa X u skup Y i pišemo

$$f : X \rightarrow Y.$$

Definicija 1.6 Kažemo da vektorska funkcija $\vec{r} : D \rightarrow \mathbb{R}^3$, $D \subseteq \mathbb{R}$, u tački $t_0 \in D$ ima izvod ako postoji limes

$$\frac{d\vec{r}(t_0)}{dt} = \lim_{\Delta t \rightarrow 0} \frac{\vec{r}(t_0 + \Delta t) - \vec{r}(t_0)}{\Delta t}.$$

1.1.1 Domen vektorske funkcije jedne realne varijable

Definicija 1.2 Domen vektorske funkcije $\vec{r}(t) = (x(t), y(t), z(t))$ je skup svih vrijednosti $t \in \mathbb{R}$ za koje su funkcionalne komponente vektora $(x(t), y(t), z(t))$ realne vrijednosti, tj. skup

$$\text{Dom}_{\vec{r}} = \{t \in \mathbb{R} \mid x(t), y(t), z(t) \in \mathbb{R}\}.$$

Definicija 1.3 Neka je vektorska funkcija $\vec{r} : D \subseteq \mathbb{R}^3 \rightarrow \mathbb{R}$ definisana u nekoj okolini tačke $t_0 \in D$, izuzev, možda, u samoj tački t_0 . Vektor $\vec{a} = (a_1, a_2, a_3)$ nazivamo limesom funkcije $\vec{r}$ kada $t \rightarrow t_0$ i pišemo

$$\lim_{t \rightarrow t_0} \vec{r}(t) = \vec{a} \quad (1.6)$$

ako za svako $\varepsilon > 0$ postoji $\delta = \delta(\varepsilon) > 0$ tako da vrijedi

$$|t - t_0| < \delta \Rightarrow |\vec{r}(t) - \vec{a}| < \varepsilon, \quad (1.7)$$

pri čemu je

$$|\vec{r}(t) - \vec{a}| = \sqrt{(x(t) - a_1)^2 + (y(t) - a_2)^2 + (z(t) - a_3)^2}. \quad (1.8)$$

Definicija 1.7 Neka je vektorska funkcija $\vec{r}$ neprekidno diferencijabilna na segmentu $I \subset \mathbb{R}$ i pri tome vrijedi $\frac{d\vec{r}}{dt}(t) \neq 0$ za sve $t \in I$ osim možda u krajnjim tačkama. Tada za krivu C pridruženu vektorskoj funkciji $\vec{r}$ kažemo da je glatka. Za krivu C kažemo da je po dijelovima glatka ako se sastoji iz konačno mnogo glatkih dijelova.

Definicija 1.8 Neka je na segmentu $I \subseteq \mathbb{R}$ definisana vektorska funkcija $\vec{r}$. Kažemo da je kriva C pridružena vektorskoj funkciji $\vec{r}$ jednostavna glatka kriva ili Jordanov luk ukoliko vrijedi $\vec{r}(t_1) \neq \vec{r}(t_2)$ za $t_1 \neq t_2$, i postoji neprekidan izvod $\frac{d\vec{r}}{dt}(t) \neq 0$ za sve $t \in I$ osim možda u krajnjim tačkama.

1.1.6 Diferencijal vektorske funkcije

Definicija 1.9 Vektorska funkcija $\vec{r}(t)$ definisana u nekoj okolini tačke t_0 naziva se diferencijabilnom u toj tački ako se njen prirast može zapisati u obliku

$$\vec{r}(t_0 + \Delta t) - \vec{r}(t_0) = \vec{A}\Delta t + \vec{\omega}(\Delta t)\Delta t$$

pri čemu je

$$\lim_{\Delta t \rightarrow 0} \vec{\omega}(\Delta t) = 0$$

1.2 Vektorske funkcije više varijabli

Definicija 1.10 Ako svakoj tački $\mathbf{x} = (x_1, \dots, x_n) \in \mathbb{R}^n$ po nekom pravilu pridružujemo jedinstven vektor $\vec{f} = \vec{f}(\mathbf{x})$, kažemo da smo definisali vektorsku funkciju $\vec{f} : \mathbb{R}^n \rightarrow \mathbb{R}^m$ n -realnih varijabli $x_1, \dots, x_n$ i pišemo

$$\vec{f}(x_1, \dots, x_n) = (f_1(x_1, \dots, x_n), \dots, f_m(x_1, \dots, x_n)), \quad (1.16)$$

pri čemu su funkcije $f_1(x_1, \dots, x_n), \dots, f_m(x_1, \dots, x_n)$ realne funkcije, $f_i : \mathbb{R}^n \rightarrow \mathbb{R}$, n realnih varijabli i nazivamo ih komponentnim funkcijama vektorske funkcije.

Vektorske funkcije još nazivamo i vektorskim poljem.

Definicija 1.13 *Parcijalnim prirastom funkcije $\vec{f}$ u tački $\mathbf{x}_0$ nazivamo razliku*

$$\Delta \vec{f}_{x_k}(\mathbf{x}_0) = \vec{f}(x_1^0, \dots, x_{k-1}^0, x_k^0 + \Delta x_k, x_{k+1}^0, \dots, x_n^0) - \vec{f}(x_1^0, \dots, x_{k-1}^0, x_k^0, x_{k+1}^0, \dots, x_n^0). \quad (1.21)$$

Definicija 1.14 *Parcijalnim izvodom prvog reda vektorske funkcije $\vec{f}(x_1, \dots, x_n)$ po varijabli x_k u tački $\mathbf{x}_0 = (x_1^0, \dots, x_n^0) \in E$ nazivamo limes*

$$\frac{\partial \vec{f}}{\partial x_k}(\mathbf{x}_0) = \lim_{\Delta x_k \rightarrow 0} \frac{\vec{f}(x_1^0, \dots, x_{k-1}^0, x_k^0 + \Delta x_k, x_{k+1}^0, \dots, x_n^0) - \vec{f}(x_1^0, \dots, x_{k-1}^0, x_k^0, x_{k+1}^0, \dots, x_n^0)}{\Delta x_k}. \quad (1.22)$$

Definicija 1.15 *(Totalnim) Prirastom funkcije $\vec{f}$ u tački $\mathbf{x}_0$ nazivamo razliku*

$$\Delta \vec{f}(\mathbf{x}_0) = \vec{f}(x_1^0 + \Delta x_1, \dots, x_n^0 + \Delta x_n) - \vec{f}(x_1^0, \dots, x_n^0) \quad (1.23)$$

Uvodeći oznaku $x_i = x_i^0 + \Delta x_i$, $i = 1, \dots, n$, tj. $\mathbf{x} = (x_1, \dots, x_n) = (x_1^0 + \Delta x_1, \dots, x_n^0 + \Delta x_n)$ prethodnu definiciju totalnog prirasta možemo zapisati kao

$$\Delta \vec{f}(\mathbf{x}_0) = \vec{f}(\mathbf{x}) - \vec{f}(\mathbf{x}_0) = \vec{f}(x_1, \dots, x_n) - \vec{f}(x_1^0, \dots, x_n^0). \quad (1.24)$$

Definicija 1.16 *Vektorska funkcija $\vec{f}(x_1, \dots, x_n)$ je diferencijabilna funkcija u tački $(x_1^0, \dots, x_n^0)$ ako se njen prirast može zapisati u obliku*

$$\Delta \vec{f}(\mathbf{x}_0) = \vec{p}_1(x_1 - x_1^0) + \dots + \vec{p}_n(x_n - x_n^0) + \vec{\omega}(\mathbf{x})d(\mathbf{x}, \mathbf{x}_0), \quad (1.25)$$

gdje je $d(\mathbf{x}, \mathbf{x}_0) = \sqrt{(x_1 - x_1^0)^2 + \dots + (x_n - x_n^0)^2}$ udaljenost između tačaka $\mathbf{x}$ i $\mathbf{x}_0$, a $\vec{\omega}(\mathbf{x})$ neprekidna vektorska funkcija za koju vrijedi

$$\lim_{\mathbf{x} \rightarrow \mathbf{x}_0} \vec{\omega}(\mathbf{x}) = \vec{\omega}(\mathbf{x}_0) = 0. \quad (1.26)$$

Definicija 1.17 *Neka je vektorska funkcija $\vec{f} : E \subseteq \mathbb{R}^n \rightarrow \mathbb{R}^m$ data sa*

$$\vec{f}(x_1, \dots, x_n) = (f_1(x_1, \dots, x_n), \dots, f_m(x_1, \dots, x_n)) \quad (1.28)$$

diferencijabilna u tački $\mathbf{x}_0 = (x_1^0, \dots, x_n^0) \in E$. Matricu

$$J(\mathbf{x}_0) = Jac_{\vec{f}}(\mathbf{x}_0) = \begin{pmatrix} \frac{\partial f_1}{\partial x_1}(\mathbf{x}_0) & \dots & \frac{\partial f_1}{\partial x_n}(\mathbf{x}_0) \\ \vdots & \dots & \vdots \\ \frac{\partial f_m}{\partial x_1}(\mathbf{x}_0) & \dots & \frac{\partial f_m}{\partial x_n}(\mathbf{x}_0) \end{pmatrix} \quad (1.29)$$

nazivamo matricom Jacobia ili jednostavnije Jakobijanom funkcije $\vec{f}$ u tački $\mathbf{x}_0$.

Ako je $m = n$ Jakobijan matrica je kvadratna i njena determinanta $\det J(\mathbf{x}_0)$ se takođe naziva Jakobijanom funkcije $\vec{f}$ u tački $\mathbf{x}_0$ i označavamo je još sa

$$\det J(\mathbf{x}_0) = \frac{D(f_1, \dots, f_n)}{D(x_1, \dots, x_n)}. \quad (1.30)$$

Teorem 1.10 (Teorem o implicitnoj funkciji) Neka je $D \subseteq \mathbb{R}^n \times \mathbb{R}^m$ otvorena oblast i neka je funkcija $\vec{F} : D \rightarrow \mathbb{R}^m$ data sa (1.31) definisana u okolini tačke $(\mathbf{x}_0, \mathbf{y}_0) = (x_1^0, \dots, x_n^0, y_1^0, \dots, y_m^0) \in D$ pri čemu vrijedi

1. Funkcija $\vec{F}$ ima neprekidne parcijalne izvode do p -tog reda zaključno u okolini tačke $(\mathbf{x}_0, \mathbf{y}_0)$,
2. $\vec{F}(\mathbf{x}_0, \mathbf{y}_0) = \vec{0}$,
3. Vrijedi

$$\frac{D(F_1, \dots, F_m)}{D(y_1, \dots, y_m)} = \begin{vmatrix} \frac{\partial F_1}{\partial y_1}(\mathbf{x}_0, \mathbf{y}_0) & \dots & \frac{\partial F_1}{\partial y_m}(\mathbf{x}_0, \mathbf{y}_0) \\ \vdots & \ddots & \vdots \\ \frac{\partial F_m}{\partial y_1}(\mathbf{x}_0, \mathbf{y}_0) & \dots & \frac{\partial F_m}{\partial y_m}(\mathbf{x}_0, \mathbf{y}_0) \end{vmatrix} \neq 0. \quad (1.36)$$

Tada postoje otvorena okolina $U \subseteq \mathbb{R}^n$ tačke $\mathbf{x}_0$ i otvorena okolina $V \subseteq \mathbb{R}^m$ tačke $\mathbf{y}_0$ i jedinstvena vektorska funkcije klase C^p $\vec{f} : U \rightarrow V$ data sa

$$(y_1, \dots, y_m) = \vec{f}(x_1, \dots, x_n) = (f_1(x_1, \dots, x_n), \dots, f_m(x_1, \dots, x_n)) \quad (1.37)$$

1. $y_i^0 = f_i(x_1^0, \dots, x_n^0) = f_i(\mathbf{x}_0)$, $i = 1, \dots, m$,
2. $\vec{F}(x_1, \dots, x_n, f_1(x_1, \dots, x_n), \dots, f_m(x_1, \dots, x_n)) = \vec{0}$ za tačke $(x_1, \dots, x_n)$ u okolini tačke $(x_1^0, \dots, x_n^0)$,
3. postoje parcijalni izvodi funkcija f_i , $i = 1, \dots, m$, u okolini tačke $(x_1^0, \dots, x_n^0)$

Teorem 1.11 (*Teorem o inverznoj funkciji) Neka je $D \subseteq \mathbb{R}^n$ otvorena oblast i $\vec{f} : D \rightarrow \mathbb{R}^n$ vektorska funkcija klase C^1 . Ako je $\mathbf{x}_0 = (x_1^0, \dots, x_n^0) \in D$ i $\det J_{\vec{f}}(\mathbf{x}_0) \neq 0$, tada postoji otvorena okolina $U \subseteq \mathbb{R}^n$ tačke $\mathbf{x}_0$ i jedinstvena otvorena okolina $V \subseteq \mathbb{R}^n$ tačke $\vec{f}(\mathbf{x}_0)$ takve da je $\vec{f}(U) = V$ i da funkcija $\vec{f}|_U$ ima inverz $\vec{f}^{-1} : V \rightarrow U$.

Dvostruki integral

Definicija 1.1 Limes integralne sume (1.3) kada maksimalni dijametar podjele $\lambda(\sigma)$ teži nuli, ako postoji, naziva se dvostruki ili dvojni integral funkcije $f(x, y)$ po pravougaonoj oblasti D i obilježava sa $\iint_D f(x, y) dx dy$.

$$\iint_D f(x, y) dx dy = \lim_{\lambda(\sigma) \rightarrow 0} \sum_{i,j=1}^n f(P_{ij}) \Delta x_i \Delta y_j. \quad (1.4)$$

Ukoliko postoji dvostruki integral funkcije f u oblasti D , kažemo da je f Riemman integrabilna na D i pišemo $f \in \mathcal{R}(D)$.

Teorem 1.1 Ako je realna funkcija f integrabilna na zatvorenoj oblasti $D \subset \mathbb{R}^2$, onda je ona i ograničena na toj oblasti.

Sljedeći teorem nam daje dovoljan uslov za integrabilnost funkcije dvije varijable na zatvorenoj oblasti $D \subseteq \mathbb{R}^2$.

Teorem 1.2 Neka je funkcija f definisana na zatvorenoj oblasti $D \subset \mathbb{R}^2$. Ako je skup tačaka prekida funkcije f mjere nula, onda je f integrabilna na oblasti D .

Specijalno, ako je funkcija f neprekidna na zatvorenoj oblasti $D \subset \mathbb{R}^2$, onda je f integrabilna na toj oblasti što nam garantuje sljedeći teorem.

Teorem 1.3 Ako je f neprekidna funkcija na zatvorenoj oblasti $D \subset \mathbb{R}^2$, onda dvostruki integral

$$\iint_D f(x, y) dx dy$$

postoji i ne zavisi od načina podjele oblasti D na podoblasti D_{ij} niti od izbora tačaka $P_{ij} \in D_{ij}$, $i, j \in \{0, 1, \dots, n-1\}$.

Teorem 1.10 (Teorem o srednjoj vrijednosti funkcije) Neka je funkcija f definisana i neprekidna u zatvorenoj oblasti $D \subset \mathbb{R}^2$. Tada postoji tačka $(x^*, y^*) \in D$ tako da vrijedi

$$\iint_D f(x, y) dx dy = f(x^*, y^*) \cdot S,$$

gdje je S površina oblasti D .

Teorem 1.12 Neka je oblast $D \subset \mathbb{R}^2$ u xy -ravni i neka je oblast $D' \subset \mathbb{R}^2$ u uv -ravni. Pretpostavimo da funkcija $\varphi : D' \rightarrow D$ zadana relacijom (1.19) bijektivno preslikava D' u D pri čemu su funkcije φ_1 i φ_2 te njihovi parcijalni izvodi $\frac{\partial \varphi_1}{\partial u}$, $\frac{\partial \varphi_1}{\partial v}$, $\frac{\partial \varphi_2}{\partial u}$, $\frac{\partial \varphi_2}{\partial v}$ neprekidni na D' i $J(u, v) = \frac{D(\varphi_1, \varphi_2)}{D(u, v)} \neq 0$, $(u, v) \in D'$. Ako

je f integrabilna funkcija na D , onda vrijedi jednakost ²

$$\iint_D f(x, y) dx dy = \iint_{D'} f(\varphi_1(u, v), \varphi_2(u, v)) |J(u, v)| du dv.$$

Teorem 1.11 (Fubinijev teorem) Neka je funkcija f integrabilna u zatvorenoj oblasti pravougaonika $D = [a, b] \times [c, d]$ i neka postoje $\int_a^b dx \int_c^d f(x, y) dy$ i $\int_c^d dy \int_a^b f(x, y) dx$. Tada vrijedi

$$\iint_D f(x, y) dx dy = \int_a^b dx \int_c^d f(x, y) dy = \int_c^d dy \int_a^b f(x, y) dx \quad (1.11)$$

Trostruki (trojni) integral

Definicija 2.1 *Limes integralne sume*

$$S(f, \sigma, P) = \sum_{i=1}^n f(P_i) m(V_i). \quad (2.2)$$

kada maksimalni dijametar podjele $d(V_i)$ teži nuli, ako postoji, naziva se trostruki integral funkcije $f(x, y, z)$ po oblasti $\mathcal{V}$ i obilježava sa

$$\iiint_{\mathcal{V}} f(x, y, z) dx dy dz$$

Ukoliko postoji trostruki integral funkcije f na oblasti $\mathcal{V}$, kažemo da je f integrabilna po Rimanu na $\mathcal{V}$ i pišemo $f \in \mathcal{R}(\mathcal{V})$.

Teorem 2.10 (Teorem o srednjoj vrijednosti funkcije) *Neka je funkcija $f(x, y, z)$ definisana i neprekidna u zatvorenoj oblasti $\mathcal{V} \subset \mathbb{R}^3$. Tada postoji tačka $(x^*, y^*, z^*) \in \mathcal{V}$ tako da vrijedi*

$$\iiint_{\mathcal{V}} f(x, y, z) dx dy dz = f(x^*, y^*, z^*) \cdot V, \quad (2.8)$$

gdje je V zapremina oblasti $\mathcal{V}$.

Definicija 2.2 *Ako je funkcija*

$$F_1(x) = \int_c^d dy \int_e^f f(x, y, z) dz \quad (2.11)$$

koja zavisi od varijable x integrabilna na segmentu $[a, b]$, tada se integral

$$\int_a^b F_1(x) dx = \int_a^b dx \int_c^d dy \int_e^f f(x, y, z) dz = \int_a^b \int_c^d \int_e^f f(x, y, z) dz dy dx \quad (2.12)$$

naziva trosrtnim integralom funkcije $f(x, y, z)$ u oblasti kvadra (2.9) pri uzastopnoj integraciji po varijablama z, y, x redom.

Ako je funkcija dvije varijable

$$F_2(x, y) = \int_e^f f(x, y, z) dz, \quad (2.13)$$

integrabilna na pravougaoniku (2.10), tada se integral

$$\iiint_{\mathcal{V}} f(x, y, z) dx dy dz = \iint_{D_{xy}} F_2(x, y) dx dy = \iint_{D_{xy}} dx dy \int_e^f f(x, y, z) dz \quad (2.14)$$

naziva trosrtnim integralom funkcije $f(x, y, z)$ u oblasti kvadra $\mathcal{V}$ pri uzastopnoj integraciji prvo po varijabli z a zatim po varijablama x, y .

Teorem 2.11 Neka je oblast $\mathcal{V} \subset \mathbb{R}^3$ u koordinatnom sistemu xyz i neka je oblast $\mathcal{V}' \subset \mathbb{R}^3$ u koordinatnom sistemu uvw . Pretpostavimo da je funkcija $\varphi : \mathcal{V}' \rightarrow \mathcal{V}$ zadana relacijom (2.23) koja zadovoljava uslove (i) i (ii) i $J(u, v, w) \neq 0$. Ako je $f \in \mathcal{R}(\mathcal{V})$ onda vrijedi jednakost

$$\iiint_{\mathcal{V}} f(x, y, z) dx dy dz = \iiint_{\mathcal{V}'} f(\varphi_1(u, v, w), \varphi_2(u, v, w), \varphi_3(u, v, w)) |J(u, v, w)| du dv dw. \quad (2.25)$$

Krivolinijski integrali

Definicija 1.1 Luk ℓ krive u prostoru nazivamo orijentisanim ako je na njemu za svake dvije tačke $T_1(x(t_1), y(t_1), z(t_1))$ i $T_2(x(t_2), y(t_2), z(t_2))$ koje odgovaraju vrijednostima parametara t_1 i t_2 , pri čemu je $t_1 < t_2$, dat jedan od sljedećih redoslijeda tačaka

1. Tačka T_1 je prethodnik tačke T_2 ;
2. Tačka T_2 je prethodnik tačke T_1

Definicija 1.2 Ako se početna i krajnja tačka krive ℓ zadate sa (1.1) poklapaju, tj. vrijedi

$$A(x(\alpha), y(\alpha), z(\alpha)) = B(x(\beta), y(\beta), z(\beta))$$

kažemo da je kriva ℓ zatvorena. Za krivu koja nije zatvorena kažemo da je otvorena.

Definicija 1.3 Za krivu ℓ pridruženu vektorskoj funkciji (1.2) kažemo da je prosta ili jednostavna kriva ako nema tačaka samopresjeka, tj. ako vrijedi

$$\vec{r}(t_1) \neq \vec{r}(t_2) \quad \text{za} \quad t_1 \neq t_2, \quad t_1, t_2 \in [\alpha, \beta].$$

Za zatvorenu krivu ℓ koja nema tačaka samopresjeka kažemo da je kontura.

Definicija 1.4 Neka je vektorska funkcija $\vec{r}$ neprekidno diferencijabilna na segmentu $I \subset \mathbb{R}$ i pri tome vrijedi $\frac{d\vec{r}}{dt}(t) \neq 0$ za sve $t \in I$ osim možda u krajnjim tačkama. Tada za krivu ℓ pridruženu vektorskoj funkciji $\vec{r}$ kažemo da je glatka. Za krivu ℓ kažemo da je po dijelovima glatka ako se sastoji iz konačno mnogo glatkih dijelova.

Definicija 1.5 Kažemo da je kriva ℓ pridružena vektorskoj funkciji (1.2) jednostavna otvorena glatka kriva ili Jordanov luk ukoliko vrijedi $\vec{r}(t_1) \neq \vec{r}(t_2)$ za

$t_1 \neq t_2$, i postoji neprekidan izvod $\frac{d\vec{r}}{dt}(t) \neq 0$ za sve $t \in [\alpha, \beta]$ osim možda u krajnjim tačkama.

1.2 Krivolinijski integrali prve vrste (Integrali po luku krive)

Definicija 1.6 Ako za realnu funkciju f definisanu i ograničenu na krivoj ℓ postoji limes

$$\lim_{\max \Delta l_i \rightarrow 0} \sum_{i=0}^{n-1} f(M_i) \Delta l_i, \quad (1.5)$$

nazivamo ga *krivolinijskim integralom prve vrste funkcije f po krivoj ℓ* i označavamo sa

$$\int_{\ell} f(x, y, z) dl \text{ ili } \int_{AB} f(x, y, z) dl. \quad (1.6)$$

1.3 Krivolinijski integrali druge vrste (Integrali po koordinatama)

Definicija 1.7 Ako za realnu funkciju P definisanu i ograničenu na luku C , postoji limes

$$\lim_{\max \Delta x_i \rightarrow 0} \sum_{i=0}^{n-1} P(M_i) \Delta x_i \quad (1.19)$$

nazivamo ga *krivolinijskim integralom druge vrste funkcije P po krivoj C* , ili *krivolinijskim integralom po koordinati x* , i označavamo sa

$$\int_C P(x, y, z) dx \text{ ili } \int_{AB} P(x, y, z) dx \quad (1.20)$$

Ako za realnu funkciju Q , definisanu i ograničenu na luku C , postoji limes

$$\lim_{\max \Delta y_i \rightarrow 0} \sum_{i=0}^{n-1} Q(M_i) \Delta y_i \quad (1.21)$$

nazivamo ga *krivolinijskim integralom druge vrste funkcije Q po krivoj C* , ili *krivolinijskim integralom po koordinati y* , i označavamo sa

$$\int_C Q(x, y, z) dy \text{ ili } \int_{AB} Q(x, y, z) dy \quad (1.22)$$

Ako za realnu funkciju R , definisanu i ograničenu na luku C , postoji limes

$$\lim_{\max \Delta z_i \rightarrow 0} \sum_{i=0}^{n-1} R(M_i) \Delta z_i \quad (1.23)$$

nazivamo je *krivolinijskim integralom druge vrste funkcije R po krivoj C* , ili *krivolinijskim integralom po koordinati z* , i označavamo sa

$$\int_C R(x, y, z) dz \text{ ili } \int_{AB} R(x, y, z) dz \quad (1.24)$$

Definicija 1.8 Krivolinijskim integralom vektorske funkcije $\vec{F}(x, y, z) = (P(x, y, z), Q(x, y, z), R(x, y, z))$ po krivoj C pridruženoj vektorskoj funkciji (1.16) ili potpunim krivolinijskim integralom druge vrste nazivamo integral

$$\begin{aligned} \int_{AB} P dx + Q dy + R dz &= \int_{AB} P(x, y, z) dx + \int_{AB} Q(x, y, z) dy + \int_{AB} R(x, y, z) dz \\ &= \int_{AB} \vec{F} \cdot d\vec{r}. \end{aligned}$$

Teorem 1.10 (Greenov teorem) Neka je $D \subset \mathbb{R}^2$ oblast ograničena dio po dio glatkom krivom C . Ako su funkcije $P(x, y)$ i $Q(x, y)$ neprekidne zajedno sa svojim parcijalnim izvodima $\frac{\partial P}{\partial y}$ i $\frac{\partial Q}{\partial x}$ na zatvorenoj oblasti $\overline{D}$, onda vrijedi jednakost

$$\oint_{C^+} P(x, y) dx + Q(x, y) dy = \iint_{\overline{D}} \left(\frac{\partial Q}{\partial x} - \frac{\partial P}{\partial y} \right) dx dy. \quad (1.32)$$

Pri tom oznaka C^+ u krivolinijskom integralu označava da se integracija vrši u smjeru pri kome tačke oblasti D ostaju s lijeve strane.

Teorem 1.12 Neka su u prosto povezanoj oblasti $V \subset \mathbb{R}^3$ zadate neprekidne funkcije $P(x, y, z)$, $Q(x, y, z)$ i $R(x, y, z)$ tako da su parcijalni izvodi $\frac{\partial P}{\partial y}$, $\frac{\partial P}{\partial z}$, $\frac{\partial Q}{\partial x}$, $\frac{\partial Q}{\partial z}$, $\frac{\partial R}{\partial x}$ i $\frac{\partial R}{\partial y}$ također neprekidni. Potreban i dovoljan uslov da integral $\int_{AB} P dx + Q dy + R dz$, $AB \subset V$, ne zavisi od putanje AB , jeste da su ispunjene jednakosti

$$\frac{\partial P}{\partial y} = \frac{\partial Q}{\partial x}, \quad \frac{\partial Q}{\partial z} = \frac{\partial R}{\partial y}, \quad \frac{\partial R}{\partial x} = \frac{\partial P}{\partial z}. \quad (1.33)$$

Površinski integrali

Definicija 2.1 Ravan T kroz tačku P_0 površi S je tangentna ravan površi S , ako tangentni vektor svake krive koja leži na površi i koja prolazi kroz tačku P_0 , pripada ravni T .

Definicija 2.2 Za površ S kažemo da je glatka ako u svakoj njenoj tački postoji tangentna ravan.

Definicija 2.3 Divergencijom vektorskog polja $\vec{F}$ nazivamo skalar

$$\operatorname{div} \vec{F} = \frac{\partial P}{\partial x} + \frac{\partial Q}{\partial y} + \frac{\partial R}{\partial z}. \quad (2.14)$$

Divergenciju još označavamo sa $\vec{\nabla} \cdot \vec{F}$, gdje je $\vec{\nabla}$ operator dat sa

$$\vec{\nabla} = \left(\frac{\partial}{\partial x}, \frac{\partial}{\partial y}, \frac{\partial}{\partial z} \right).$$

Definicija 2.4 Rotorom vektorske funkcije (vektorskog polja) $\vec{F}$ nazivamo vektor

$$\text{rot } \vec{F} = \left(\frac{\partial R}{\partial y} - \frac{\partial Q}{\partial z} \right) \vec{i} + \left(\frac{\partial P}{\partial z} - \frac{\partial R}{\partial x} \right) \vec{j} + \left(\frac{\partial Q}{\partial x} - \frac{\partial P}{\partial y} \right) \vec{k}. \quad (2.15)$$

Izraz na desnoj strani prethodne definicije možemo zapisati u obliku determinante

$$\text{rot } \vec{F} = \vec{\nabla} \times \vec{F} = \begin{vmatrix} \vec{i} & \vec{j} & \vec{k} \\ \frac{\partial}{\partial x} & \frac{\partial}{\partial y} & \frac{\partial}{\partial z} \\ P & Q & R \end{vmatrix}.$$

Rotor vektorskog polja $\text{rot } \vec{F}$ opisuje lokalne cirkulacije u okolini tačke.

Definicija 2.5 Limesintegralne sume (2.26) kada $\max_{1 \leq i \leq n} d(S_i) \rightarrow 0$ nazivamo površinskim integralom prve vrste funkcije $f(x, y, z)$ po površi S i označavamo sa

$$\iint_S f(x, y, z) dS = \lim_{\max_{1 \leq i \leq n} d(S_i) \rightarrow 0} \sum_{i=1}^n f(x_i, y_i, z_i) m(S_i). \quad (2.18)$$

Definicija 2.6 Granične vrijednosti integralnih suma datih sa (2.29) kad $\max_{1 \leq i \leq n} d(S_i) \rightarrow 0$ nazivaju se površinskim integralima druge vrste ili površinskim integralima po koordinatama funkcije $f(x, y, z)$ po površi S i označavaju se sa

$$\begin{aligned} \iint_S f(x, y, z) \cos \alpha dS &= \lim_{\max_{1 \leq i \leq n} d(S_i) \rightarrow 0} \sum_{i=1}^n f(x_i, y_i, z_i) \cos \alpha_i \cdot m(S_i), \\ \iint_S f(x, y, z) \cos \beta dS &= \lim_{\max_{1 \leq i \leq n} d(S_i) \rightarrow 0} \sum_{i=1}^n f(x_i, y_i, z_i) \cos \beta_i \cdot m(S_i), \\ \iint_S f(x, y, z) \cos \gamma dS &= \lim_{\max_{1 \leq i \leq n} d(S_i) \rightarrow 0} \sum_{i=1}^n f(x_i, y_i, z_i) \cos \gamma_i \cdot m(S_i). \end{aligned} \quad (2.30)$$

Definicija 2.7 Potpuni (opšti) površinski integral druge vrste je integral

$$\begin{aligned} \iint_S (P \cos \alpha + Q \cos \beta + R \cos \gamma) dS &= \iint_S P(x, y, z) \cos \alpha dS + \iint_S Q(x, y, z) \cos \beta dS \\ &+ \iint_S R(x, y, z) \cos \gamma dS, \end{aligned}$$

gdje su funkcije P , Q i R definisane na površi S .

2.4.1 Definicija površinskih integrala druge vrste

Neka je glatka orijentisana površ $S \subset \mathbb{R}^3$ ograničena dio po dio glatkom krivom i data jednačinom

$$\vec{r}(u, v) = x(u, v) \vec{i} + y(u, v) \vec{j} + z(u, v) \vec{k}, \quad (u, v) \in D, \quad (2.28)$$

gdje je $\frac{\partial \vec{r}}{\partial u} \times \frac{\partial \vec{r}}{\partial v} \neq \vec{0}$ i D mjerljiva zatvorena oblast u uv -ravni, a funkcije $x(u, v)$, $y(u, v)$ i $z(u, v)$ su neprekidno diferencijabilne na D .

Teorem 2.7 (Stokesov teorem) *Neka je S ograničena, po dijelovima glatka, dvostрана površ, gdje je $\vec{n}$ vektorsko polje vanjskih normala na S , sa dio po dio glatkom granicom C orijentisanom tako da prilikom obilaska orijentisane površi po krivnoj C površ S ostaje sa lijeve strane. Neka su funkcije $P(x, y, z)$, $Q(x, y, z)$,*

$R(x, y, z)$ neprekidne i imaju neprekidne parcijalne izvode u nekoj okolini površi S . Tada vrijedi

$$\oint_C Pdx + Qdy + Rdz = \iint_S \left(\frac{\partial R}{\partial y} - \frac{\partial Q}{\partial z} \right) dydz + \left(\frac{\partial P}{\partial z} - \frac{\partial R}{\partial x} \right) dzdx + \left(\frac{\partial Q}{\partial x} - \frac{\partial P}{\partial y} \right) dxdy,$$

Teorem 2.8 (Teorem Gaussa-Ostrogradskog. Divergencijski teorem) *Neka je $V \subset \mathbb{R}^3$ zatvorena oblast ograničena dio po dio glatkom površi S bez samopresjeka i neka je $\vec{n}$ vektorsko polje vanjskih normala na S . Neka su u oblasti V definisane neprekidne funkcije $P(x, y, z)$, $Q(x, y, z)$, $R(x, y, z)$ i koje imaju neprekidne parcijalne izvode $\frac{\partial P}{\partial x}$, $\frac{\partial Q}{\partial y}$, $\frac{\partial R}{\partial z}$. Tada vrijedi jednakost*

$$\iint_S Pdydz + Qdzdx + Rxdy = \iiint_V \left(\frac{\partial P}{\partial x} + \frac{\partial Q}{\partial y} + \frac{\partial R}{\partial z} \right) dxdydz. \quad (2.35)$$

Klasifikacija vektorskih polja

Vektorska polja klasifikujemo na osnovu vrijednosti koje mogu imati divergencija i rotor.

1. Potencijalnim (konzervativnim, bezvrtložnim ili lamelarnim) vektorskim poljima nazivamo vektorska polja definisana u prosto povezanoj oblasti u čijim tačkama vrijedi

$$\text{rot } \vec{F} = \vec{0} \wedge \text{div } \vec{F} \neq 0, \quad (3.1)$$

pri čemu $\text{div } \vec{F}$ može biti jednak nuli u nekim tačkama.

Može se pokazati da je neprekidno diferencijabilno polje $\vec{F}$ na prosto povezanoj oblasti potencijalno ako i samo ako postoji realna funkcija $U(x, y, z)$ takva da je

$$\vec{F} = \nabla U = \text{grad } U.$$

U tom slučaju za funkciju U kažemo da je potencijal vektorskog polja $\vec{F}$.

2. Solenoidnim (vrtložnim) vektorskim poljima nazivamo vektorska polja u čijim je tačkama

$$\text{div } \vec{F} = 0 \wedge \text{rot } \vec{F} \neq \vec{0}, \quad (3.2)$$

pri čemu $\text{rot } \vec{F}$ može biti jednak nuli u nekim tačkama.

Može se pokazati da ako je polje $\vec{F}$ solenoidno, tada postoji vektorsko polje $\vec{F}_1$ takvo da je

$$\vec{F} = \text{rot } \vec{F}_1,$$

gdje se vektor $\vec{F}_1$ zove vektorskim potencijalom polja $\vec{F}$.

3. Laplaceovim vektorskim poljima nazivamo vektorska polja u čijim je svim tačkama

$$\text{div } \vec{F} = 0 \wedge \text{rot } \vec{F} = \vec{0} \quad (3.3)$$

4. Složenim vektorskim poljima nazivamo vektorska polja u čijim je tačkama

$$\text{div } \vec{F} \neq 0 \wedge \text{rot } \vec{F} \neq \vec{0}, \quad (3.4)$$

pri čemu $\text{div } \vec{F}$ i $\text{rot } \vec{F}$ mogu biti jednaki nuli u nekim tačkama.

Diferencijalne jednačine i rješenja

Definicija

Jednačinu koja sadrži izvode funkcije (zavisne varijable) od jedne ili više nezavisnih varijabli nazivamo diferencijalnom jednačinom.

- Diferencijalne jednačine dijelimo prema

1. tipu,
2. redu i
3. linearnosti.

Podjela diferencijalnih jednačina prema tipu

1. Obične diferencijalne jednačine (ODJ) - sadrže izvode funkcije y koja zavisi od samo jedne nezavisne varijable
2. Parcijalne diferencijalne jednačine - sadrže parcijalne izvode funkcije u koja zavisi od više nezavisnih varijabli.

Podjela ODJ-a prema redu

- Red ODJ-e je jednak redu najvišeg izvoda funkcije (zavisne varijable) u jednačini.
- ODJ-e prema redu dijelimo na
- jednačine prvog reda - sadrže nezavisnu varijablu x , zavisnu varijablu y i izvod prvog reda zavisne varijable y' .
 - jednačine višeg reda (n -tog reda) - sadrže nezavisnu varijablu x , zavisnu varijablu y i izvode do n -tog reda zavisne varijable, $y', y'', \dots, y^{(n)}$.

1. Linearne ODJ zadovoljavaju sljedeće uslove

- 1.1 zavisna varijabla y i svi njeni izvodi su stepena najviše jedan i
- 1.2 koeficijenti $a_0, \dots, a_n$ uz $y, y', \dots, y^{(n)}$ mogu zavisiti samo od nezavisne varijable x .

$$(y - x)dx = -4xdy, \quad y'' - 2y' + y = 0, \quad y''' + x^2y' - 5y = e^x$$

2. Nelinearne ODJ-e su diferencijalne jednačine koje nisu linearne, tj. vrijedi jedna od sljedećih situacija:

- 2.1 zavisna varijabla se pojavljuje u argumentu druge funkcije,

$$y'' + \sin y = 0, \quad e^{x-y}y' = \sin x;$$

- 2.2 izvod zavisne varijable se pojavljuje u argumentu druge funkcije,

$$e^{y'} + y' = x$$

- 2.3 funkcionalni koeficijent uz neki od izvoda $y', \dots, y^{(n)}$ zavisi od y

$$(1 - y)y' + 2y = e^x.$$

Definicija

Oblast definisanosti ODJ-e $y' = f(x, y)$, odnosno recipročne diferencijalna jednačine $x' = \frac{1}{f(x, y)}$ je unija oblasti definisanosti funkcija $f(x, y)$ i $\frac{1}{f(x, y)}$ i ne sadrži tačke u kojima su ove funkcije neodređene.

Oblast definisanosti ODJ-e u simetričnom obliku su sve tačke koje pripadaju oblastima definisanosti funkcija $M(x, y)$ i $N(x, y)$ i za koje vrijedi

$$M^2(x, y) + N^2(x, y) \neq 0.$$

Definicija

Neka je funkcija $f(x, y)$, definisana na nekom skupu $D \subset \mathbb{R}^2$. Za funkciju $y = \varphi(x)$ definisanu u intervalu (a, b) kažemo da je rješenje jednačine $y' = f(x, y)$ ako za svako $x \in (a, b)$ vrijedi

- 1. Postoji izvod funkcije $\varphi(x)$ za svako $x \in (a, b)$
- 2. Nakon uvrštavanja funkcije $y = \varphi(x)$ u jednačinu, ona postaje identitet

$$\varphi'(x) \equiv f(x, \varphi(x))$$

za svako $x \in (a, b)$,

tj. za svako $x \in (a, b)$ $(x, \varphi(x)) \in D$ i $\varphi'(x) = f(x, \varphi(x))$.

Rješenje ODJ-e u parametarskom obliku

Definicija

Relacijom $x = \varphi(t), y = \psi(t)$ je definisano rješenje jednačine $y' = f(x, y)$ u parametarskom obliku na intervalu (α, β) ako u tom intervalu identički vrijedi

$$\frac{\psi'(t)}{\varphi'(t)} \equiv f(\varphi(t), \psi(t)).$$

Definicija

Familiju rješenja diferencijalne jednačine koja zavise od proizvoljne konstante C datu sa

$$y = \varphi(x, C)$$

nazivamo Opštim rješenjem jednačine

Definicija

Rješenje ODJ-e koje možemo dobiti iz opšteg rješenja za neku vrijednost konstante C (uključujući $\pm\infty$) nazivamo partikularnim rješenjem.

Definicija

Rješenje koje ne možemo dobiti iz opšteg rješenja niti za jednu vrijednost konstante C (uključujući $C = \pm\infty$) nazivamo singularnim rješenjem. Integralna kriva koja odgovara singularnom rješenju se naziva singularnom.

Definicija

Kriva u čijoj svakoj tački pravac polja, koji je definisan diferencijalnom jednačinom $y' = f(x, y)$, ima istu vrijednost naziva se izoklina. Jednačina izokline glasi

$$f(x, y) = k, \quad k \in \mathbb{R}$$

Definicija

- ▶ Ako PPV (Cauchyev problem) ima više od jednog rješenja ili nema rješenja, kažemo da je u tački (x_0, y_0) narušena jedinstvenost rješenja Cauchyevog problema.
- ▶ Ako desna strana jednačine $y' = f(x, y)$ u tački (x_0, y_0) postaje beskonačna kažemo da je to singularni slučaj PPV-a (Cauchyevog problema). Tada posmatramo recipročnu jednačinu i tražimo ono rješenje koje zadovoljava početni uslov.
- ▶ Ako je desna strana jednačine $y' = f(x, y)$ u tački (x_0, y_0) oblika $\frac{0}{0}$ kažemo da Cauchyev problem nema smisla jer niti jedna integralna kriva ne prolazi datom tačkom. Tada tražimo ono rješenje koje se približava tački (x_0, y_0) .
- ▶ Neprekidnost funkcije $f(x, y)$ je dovoljan uslov za egzistenciju bar jednog rješenja Cauchyevog problema

$$y' = f(x, y), \quad y(x_0) = y_0$$

u dovoljno maloj okolini tačke (x_0, y_0) .

Teorem (Peanov teorem)

Neka je u oblasti D xy-ravni definisana realna funkcija $f(x, y)$ i neka je neprekidna na D . Tada za svako $(x_0, y_0) \in D$ Cauchyev problem

$$y' = f(x, y), \quad y(x_0) = y_0$$

ima bar jedno rješenje koje je definisano na intervalu $|x - x_0| \leq h$, pri čemu broj h ne zavisi od tačke (x_0, y_0)

Teorem (Cauchy-Picardov teorem)

Posmatrajmo Cauchyev problem

$$y' = f(x, y), \quad y(x_0) = y_0.$$

Pretpostavimo da su funkcije f i $\frac{\partial f}{\partial y}$ neprekidne na nekom pravougaoniku

$$\mathcal{R} = \{(x, y) | |x - x_0| \leq a, |y - y_0| \leq b, a > 0, b > 0\}$$

koji je opisan oko tačke (x_0, y_0) . Tada postoji pozitivan broj $h \leq a$ takav da Cauchyev problem ima jedno i samo jedno rješenje koje je definisano na intervalu $|x - x_0| \leq h$.

Definicija

Podskup oblasti definisanosti D ODJ-e $y' = f(x, y)$ kroz čiju svaku tačku prolazi samo jedna integralna kriva, nazivamo oblast egzistencije i jedinstvenosti rješenja posmatrane jednačine i označavamo sa $\mathcal{E}$.

Teorem (Veza između određenog integrala i izvoda na segmentu)

Neka je funkcija $f(x)$ definisana i neprekidna u svakoj tački segmenta $[a, b]$. Tada funkcija $F(x) = \int_a^x f(t)dt$ ima izvod za sve $x \in [a, b]$ i $F(x)$ je primitivna funkcija funkcije $f(x)$ na segmentu $[a, b]$, tj. vrijedi

$$F'(x) = f(x), \quad \forall x \in [a, b].$$

Definicija

Za funkciju $g(x, y)$ kažemo da je homogena funkcija stepena homogenosti m ako za svako $t \in \mathbb{R}$ vrijedi

$$g(tx, ty) = |t|^m g(x, y). \quad (7)$$

Definicija

Neka su funkcije $M(x, y), N(x, y)$ definisane i neprekidne u jednostruko povezanoj oblasti $D \subset \mathbb{R}^2$ i neka je $M^2(x, y) + N^2(x, y) \neq 0$ za sve $(x, y) \in D$. Jednačinu oblika

$$M(x, y)dx + N(x, y)dy = 0 \quad (1)$$

nazivamo jednačinom totalnog diferencijala ako je njena lijeva strana totalni diferencijal realne funkcije f definisane u oblasti $D \subseteq \mathbb{R}^2$, tj. ako za svako $(x, y) \in D$ vrijedi

$$df(x, y) = \frac{\partial f}{\partial x}(x, y)dx + \frac{\partial f}{\partial y}(x, y)dy = M(x, y)dx + N(x, y)dy$$

Definicija

Funkcija $\mu(x, y)$ definisana i neprekidna sa neprekidnim parcijalnim izvodima prvog reda u oblasti D , koja je različita od nule u toj oblasti, nazivamo integracionim faktorom diferencijalne jednačine $M(x, y)dx + N(x, y)dy = 0$ ako je jednačina

$$\mu(x, y)M(x, y)dx + \mu(x, y)N(x, y)dy = 0$$

jednačina totalnog diferencijala.

Definicija

Funkcija $\varphi(x)$, definisana na intervalu (a, b) je rješenje jednačine $F(x, y, y') = 0$ ako za svako $x \in (a, b)$ vrijedi

1. Postoji izvod funkcije $\varphi(x)$,
2. $(x, \varphi(x), \varphi'(x)) \in D$,
3. $F(x, \varphi(x), \varphi'(x)) = 0$.

Teorem (Teorem o egzistenciji i jedinstvenosti)

Neka je funkcija $F(x, y, y')$ definisana i neprekidna i sa neprekidnim parcijalnim izvodima prvog reda po y i y' u nekoj okolini tačke $(x_0, y_0, y'_0) \in D$, pri čemu je $F(x_0, y_0, y'_0) = 0$ i $F'_{y'}(x_0, y_0, y'_0) \neq 0$. Onda diferencijalna jednačina $F(x, y, y') = 0$ ima jedinstveno rješenje $\varphi(x)$, definirano i neprekidno diferencijabilno u nekoj okolini tačke x_0 , koje zadovoljava uslove $\varphi(x_0) = y_0, \varphi'(x_0) = y'_0$.

Diferencijalne jednačine višeg reda

Definicija

Za funkciju $y = \varphi(x)$ definisanu u intervalu (a, b) kažemo da je rješenje jednačine $y^{(n)} = f(x, y, y', \dots, y^{(n-1)})$ ako za svako $x \in (a, b)$ vrijedi

1. Postoji $\varphi^{(n)}(x)$
2. $(x, \varphi(x), \varphi'(x), \dots, \varphi^{(n-1)}(x)) \in \mathcal{O}$
3. $\varphi^{(n)}(x) = f(x, \varphi(x), \varphi'(x), \dots, \varphi^{(n-1)}(x))$

Definicija

Neka je $\mathcal{E}$ oblast egzistencije i jedinstvenosti rješenja diferencijalne jednačine $y^{(n)} = f(x, y, y', \dots, y^{(n-1)})$. Funkcija $y = \varphi(x, C_1, C_2, \dots, C_n)$ definisana u nekoj oblasti K varijabli $x, C_1, C_2, \dots, C_n$ je opšte rješenje date diferencijalne jednačine ako vrijedi

1. $\varphi(x, C_1, C_2, \dots, C_n)$ je n puta neprekidno diferencijabilna po x u oblasti K .
2. sistem

$$\begin{aligned} y &= \varphi(x, C_1, C_2, \dots, C_n) \\ y' &= \varphi'(x, C_1, C_2, \dots, C_n) \\ &\dots \\ y^{(n-1)} &= \varphi^{(n-1)}(x, C_1, C_2, \dots, C_n) \end{aligned} \quad (5)$$

je rješiv po $C_1, C_2, \dots, C_n$ u oblasti $\mathcal{E}$, tj.

$C_i = \psi_i(x, y, y', \dots, y^{(n-1)}), i = 1, \dots, n$ za svako $(x, y, y', \dots, y^{(n-1)}) \in \mathcal{E}$.

3. Funkcija $y = \varphi(x, C_1, C_2, \dots, C_n)$ je rješenje početne jednačine za bilo koje vrijednosti $C_1, C_2, \dots, C_n$.

Teorem (Peanov teorem)

Neka je u oblasti $\mathcal{O} \subset \mathbb{R}^{n+1}$ definisana i neprekidna funkcija $f(x, y, y', \dots, y^{(n-1)})$. Tada za svako $(x_0, y_0, y_1, \dots, y_{n-1}) \in \mathcal{O}$ PPV

$$\begin{aligned} y^{(n)} &= f(x, y, y', \dots, y^{(n-1)}) \\ y(x_0) &= y_0 \\ y'(x_0) &= y_1^0 \\ &\dots \\ y^{(n-1)}(x_0) &= y_{n-1}^0 \end{aligned} \quad (6)$$

ima bar jedno rješenje koje je definisano bar na jednom segmentu $|x - x_0| \leq h$.

Teorem (Cauchy-Picardov teorem)

Pretpostavimo da je funkcija $f(x, y, y', \dots, y^{(n-1)})$ definisana na nekoj zatvorenoj i ograničenoj oblasti

$$\mathcal{R} = \{(x, y, y', \dots, y^{(n-1)}) \in \mathbb{R}^{n+1} \mid |x - x_0| \leq a, |y - y_0| \leq b, |y' - y_1^0| \leq b, \dots, |y^{(n-1)} - y_{n-1}^0| \leq b, a > 0, b$$

i da zadovoljava sljedeće uslove

1. funkcija $f(x, y, y', \dots, y^{(n-1)})$ je neprekidna po svim svojim argumentima (time i ograničena)
2. funkcija $f(x, y, y', \dots, y^{(n-1)})$ ima ograničene parcijalne izvode po argumentima $y, y', \dots, y^{(n-1)}$

Tada postoji pozitivan broj $h \leq a$ takav da Cauchyev problem (4) ima jedno i samo jedno rješenje koje je definisano na intervalu $|x - x_0| \leq h$.

Definicija

Funkcije $y_1(x), \dots, y_n(x)$, definisane na intervalu (a, b) , su linearno zavisne na tom intervalu ako postoje koeficijenti $\alpha_1, \dots, \alpha_n \in \mathbb{R}$ od kojih je bar jedan različit od nule i pri tome vrijedi

$$\alpha_1 y_1(x) + \dots + \alpha_n y_n(x) = 0, \quad x \in (a, b) \quad (12)$$

Funkcije $y_1(x), \dots, y_n(x)$, definisane na intervalu (a, b) , su linearno nezavisne na tom intervalu ako je identitet (12) zadovoljen samo za $\alpha_1 = \dots = \alpha_n = 0$.

Definicija

Neka su funkcije $y_1 = y_1(x), \dots, y_n = y_n(x)$ definisane na intervalu (a, b) i imaju izvode bar do $(n-1)$ -og reda. Tada se determinanta

$$W(x) = W(y_1, y_2, \dots, y_n) = \begin{vmatrix} y_1 & y_2 & \dots & y_n \\ y_1' & y_2' & \dots & y_n' \\ \dots & \dots & \dots & \dots \\ y_1^{(n-1)} & y_2^{(n-1)} & \dots & y_n^{(n-1)} \end{vmatrix}$$

naziva funkcionalna determinanta ili Wronskian funkcija $y_1, y_2, \dots, y_n$.

Teorem

Neka su funkcije $y_1(x), \dots, y_n(x) \in C^n(a, b)$ rješenja homogene diferencijalne jednačine

$$y^{(n)} + p_1(x)y^{(n-1)} + \dots + p_n(x)y = 0$$

i neka $p_1(x), \dots, p_n(x) \in C(a, b)$.

Rješenja $y_1(x), \dots, y_n(x)$ su linearno nezavisna na intervalu (a, b) ako i samo ako je

$$W(x) \neq 0 \text{ za svako } x \in (a, b).$$

Teorem

Ako su rješenja $y_1 = y_1(x), \dots, y_n = y_n(x) \in C^n(a, b)$ jednačine

$$y^{(n)} + p_1(x)y^{(n-1)} + \dots + p_n(x)y = 0$$

linearno nezavisna na intervalu (a, b) i $x_0 \in (a, b)$ proizvoljna ali fiksna tačka, onda je

$$W(x) = W(x_0)e^{-\int_{x_0}^x p_1(t)dt}, x \in (a, b). \quad (13)$$

Formula iz prethodnog teorema zove se formula Ostrogradski-Liouvillea.

Posljedica

Ako je $W(x_0) = 0$ za neko $x_0 \in (a, b)$, onda je $W(x) = 0$ za svako $x \in (a, b)$.

Ako je $W(x_0) \neq 0$ za neko $x_0 \in (a, b)$, onda je $W(x) \neq 0$ za svako $x \in (a, b)$.

Teorem

Opšte rješenje nehomogene linearne diferencijalne jednačine

$$y^{(n)} + p_1(x)y^{(n-1)} + \dots + p_n(x)y = f(x)$$

je suma općeg rješenja odgovarajuće homogene linearne diferencijalne jednačine

i bilo kojeg partikularnog rješenja nehomogene linearne diferencijalne jednačine.