

Vjerovatnoća i statistika – usmeni ispit, često postavljena pitanja

1. Kada su dva događaja nezavisna?

Dva događaja su nezavisna ako i samo ako $P(A \cap B) = P(A) \cdot P(B)$. Za događaje kažemo da su **uzajamno nezavisni** ako svaki podskup ovog skupa događaja čini nezavisne događaje.

2. Šta je koeficijent relacije?

Koeficijenti korelacije izražavaju mjeru povezanosti između dvije varijable u jedinicama nezavisnima o konkretnim jedinicama mjere u kojima su iskazane vrijednosti varijabli.

3. Šta je statistika?

Funkcija slučajne promjenljive koju formira uzorak se naziva **statistika**.

4. Kada su dvije slučajne promjenjive nezavisne i zavisne? (preko definicije sa distribucijama)

Neka su X i Y dvije slučajne (diskretne ili neprekidne) promjenljive sa zajedničkom funkcijom distribucije $f(x, y)$ i marginalnim distribucijama $g(x)$ i $h(y)$. Za X i Y kažemo da su **statistički nezavisne** ako vrijedi $f(x, y) = g(x)h(y)$ za sve vrijednosti (x, y) unutar ranga.

Napomena: Ako postoji bar jedan par (x, y) takav da je $f(x, y) \neq g(x)h(y)$ tada slučajne promjenljive X i Y **nisu statistički nezavisne**.

5. Binomni proces - binomna distribucija

Eksperiment se sastoji od ponovljenih pokušaja. Svaki pokušaj ima dva moguća ishoda: **uspjeh i neuspjeh**. Vjerovatnoća uspjeha p je konstantna pri svakom pokušaju. Ponovljeni pokušaji su nezavisni. $P(X = x) = b(x; n, p)$ [x broj uspješnih ishoda; n broj pokušaja; p vjerovatnoća uspjeha]

$$b(x; n, p) = \binom{n}{x} p^x q^{n-x} \quad \mu = np \text{ and } \sigma^2 = npq.$$

6. Gdje koristimo normalnu distribuciju?* (nisam sigurna je li se misli samo na ovo)

Jedna od najvažnijih distribucija i približno opisuje mnoge fenomene u prirodi, sociologiji, industriji itd.

7. Opisati klasični pristup za testiranje hipoteze.

Klasični pristup:

- Utvrditi null i alternativnu hipotezu
- Izabrati i fiksirati nivo značaja α
- Izabrati testnu statistiku i utvrditi kritični interval na osnovu α
- Odbaciti nulhipotezu ukoliko je vrijednost testne statistike u uzorku u kritičnom regionu. U suprotnom je prihvatamo.
- Donijeti zaključak

8. Poissonov proces (distribucija)

Poissonov proces:

- Poissonov proces nema memoriju
- Vjerovatnoća da će se događaj desiti u nekom malom vremenskom intervalu je proporcionalna dužini vremenskog intervala i ne zavisi od broja događaja van ovog intervala
- Vjerovatnoća da će se dva događaja desiti unutar malog vremenskog intervala je zanemarljiva

- $$p(x; \lambda t) = \frac{e^{-\lambda t} (\lambda t)^x}{x!}$$

Poissonova distribucija:

- X je broj pojavljivanja
- Lambda je prosječan broj pojavljivanja po jedinici vremena/površini
- E(X) i Var(X) je lambda * t

9. Šta je vjerovatnoća?

Relativna frekvencija događaja.

10. Greška tipa II.

Ona se dešava u slučaju kada prihvatamo nulhipotezu iako je ona pogrešna. Vjerovatnoća da ćemo počiniti grešku tipa II je β .

11. Šta su moda i medijana?

Moda uzorka je aritmetička sredina njegovih vrijednosti.

Neka je dat niz $x_1, x_2, x_3, \dots, x_n$ u rastućem redoslijedu. **Medijana** je definisana sa:

- $X = x_{(n+1)/2}$ za n **neparno**
- $X = \frac{1}{2} * (x_{n/2} + x_{(n+2)/2})$ za n **parno**.

12. Kad koristimo t distribuciju?

Koristimo kad ne znamo varijansu populacije, ali znamo varijansu uzorka.

13. Čime možemo zamijeniti binomnu distribuciju za velike uzorke?

Ako su uzorci veliki možemo aproksimirati normalnom distribucijom.

14. Uniformna distribucija

Uniformna neprekidna distribucija ima jednaku funkciju raspodjele na nekom intervalu [A,B].

15. Matematičko očekivanje

Neka je X slučajna promjenljiva sa distribucijom f(x). Očekivana vrijednost od X je $\mu = E(x) = \sum(x * f(x))$ kada je x diskretna $\mu = E(x) = \int x * f(x) dx$ kada je x kontinualna [u granicama od $-\infty$ do $+\infty$]

16. Binomni proces

Eksperiment se sastoji od ponovljenih pokušaja. Svaki pokušaj ima dva moguća ishoda: **uspjeh i neuspjeh**. Vjerovatnoća uspjeha p je konstantna pri svakom pokušaju. Ponovljeni pokušaji su nezavisni. $P(X = x) = b(x; n, p)$ [x broj uspješnih ishoda; n broj pokušaja; p vjerovatnoća uspjeha]

17. Normalna distribucija

Jedna od najvažnijih distribucija i približno opisuje mnoge fenomene u prirodi, sociologiji, industriji itd. Grafik je zvonasta kriva koja je u potpunosti određena sa **modom** i sa **varijansom**.

Binomna i normalna raspodjela dobro aproksimiraju jedna drugu. Aproksimacija je dobra ili za velike n ili za p približno 0,5.

18. Uslovna vjerovatnoća

Ako posmatramo događaj uz neku restrikciju dolazimo do pojma uslovne vjerovatnoće. Ako su A i B događaji vjerovatnoća da se desio događaj A ako znamo da se desio događaj B nazivamo **uslovna vjerovatnoća** događaja A pod uslovom B $P(A | B)$. $P(A | B) = P(A \cap B) / P(B)$

Ako postoje uslovne vjerovatnoće, za događaje A i B kažemo da su (statistički) nezavisni ako je $P(A | B) = P(A)$ ili $P(B | A) = P(B)$.

19. Greška I tipa

Ona se dešava u slučaju kada odbijamo nulhipotezu iako je ona tačna. Vjerovatnoća da ćemo počiniti grešku tipa I naziva se **nivo signifikantnosti α** .

20. Šta je permutacija?

Permutacija je utvrđivanje redoslijeda u skupu objekata.

Broj permutacija od n objekata: Za prvu poziciju imamo n izbora, na drugu poziciju ne možemo postaviti već izabrani element, itd. Pa je broj permutacija

$$n \cdot (n - 1) \cdot (n - 2) \cdot \dots \cdot 1 = n!$$

21. Šta su permutacije s ponavljanjem?

Broj načina da n objekat smjestimo u r ćeliju gdje je n_1 objekat u prvoj ćeliji, n_2 objekat u drugoj ćeliji itd. gdje je $n_1 + n_2 + \dots + n_r = n$ je:

$$\frac{n!}{n_1! n_2! \dots n_r!}$$

22. Šta je distribucija?

U statistici, distribucija je matematički izraz koji opisuje vjerovatnoću da će neka veličina poprimiti određenu vrijednost ili skup vrijednosti, raspodjela frekvencija kojima se u nekom skupu rezultata, poredanih od manjih prema većima, pojavljuju pojedini rezultati.

23. Šta je kumulativna funkcija distribucije?

U teoriji vjerovatnoće i statistike, kumulativna funkcija distribucije (CDF) realne slučajne varijable X ili samo funkcija distribucije X , procijenjena na x , je vjerovatnoća da će X dobiti vrijednost manju ili jednaku x .

24. Kako glasi Čebišljev teorem?

Vjerovatnoća da slučajna promjenljiva ima vrijednost standardnih devijacija od očekivanih vrijednosti je veća od $1 - \frac{1}{k^2}$, tj.

$$P(\mu - k\sigma < X < \mu + k\sigma) \geq 1 - \frac{1}{k^2}$$

25. Šta je testna statistika?

Statistika na osnovu koje se donosi odluka o odbacivanju/prihvatanju zadane hipoteze.

Testna statistika na osnovu koje donosimo odluku je slučajna varijabla P_1 P_2 . Izaberemo dva uzorka n_1 i n_2 i iz njih izračunamo tražene vrijednosti.

26. Zašto je kumulativna funkcija distribucije bolja od funkcije gustoće vjerovatnoće?

Zato što može dati informaciju o vjerovatnoći čitavog intervala bez da se sumiraju sve od početka do kraja, ili integriraju ako je kontinualna.

27. Šta je totalna vjerovatnoća?

Ako događaji $B_1, B_2, \dots, B_k$ čine particiju skupa ishoda S pri čemu $P(B_i) \neq 0, i = 1, 2, \dots, k$, tada za svaki događaj A iz S vrijedi

$$P(A) = \sum_{i=1}^k P(A \cap B_i) = \sum_{i=1}^k P(B_i)P(A|B_i)$$

28. Kako glasi Bayesovo pravilo?

Neka događaji $B_1, B_2, \dots, B_k$ čine particiju skupa ishoda S pri čemu $P(B_i) \neq 0, i = 1, 2, \dots, k$. Za svaki događaj A takav da je $P(A) \neq 0$, vrijedi

$$P(B_r|A) = \frac{P(B_r \cap A)}{\sum_{i=1}^k P(B_i \cap A)} = \frac{P(B_r)P(A|B_r)}{\sum_{i=1}^k P(B_i)P(A|B_i)}$$

za $r=1, 2, \dots, k$.

Ili, jednostavnije:

$$P(A|B) = \frac{P(B|A) \cdot P(A)}{P(B)}$$

A, B = events

$P(A|B)$ = probability of A given B is true

$P(B|A)$ = probability of B given A is true

$P(A), P(B)$ = the independent probabilities of A and B

29. Od čega zavisi oblik grafika normalne distribucije?

Oblik grafika normalne distribucije zavisi od standardne devijacije/varijanse i mode.

30. Šta su cirkularne/kružne permutacije?

Permutacije koje se računaju kao $(n-1)!$. Primjer: okrugli stol.